



Universidad Politécnica
de Madrid



**Escuela Técnica Superior de
Ingenieros Informáticos**

Grado en Ingeniería Informática

Trabajo Fin de Grado

**Análisis de Rendimiento en el Fútbol
Profesional Usando Aprendizaje
Automático**

Autor: Gonzalo Salas Saiz

Tutor(a): Óscar Corcho García

Madrid, junio 2025

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ingeniería Informática

Título: Análisis de Rendimiento en el Fútbol Profesional Usando Aprendizaje Automático

Junio 2025

Autor: Gonzalo Salas Saiz

Tutor:

Óscar Corcho García
Departamento de Inteligencia Artificial
ETSI Informáticos
Universidad Politécnica de Madrid

Resumen

En los últimos años, el fútbol profesional ha sufrido una gran transformación gracias a la utilización de la tecnología en todos los aspectos de este deporte. La incorporación de herramientas como el análisis de datos, ha sido clave para la optimización del rendimiento de los equipos de fútbol profesionales. Más allá de la intuición y la experiencia de los cuerpos técnicos, los clubes y selecciones nacionales recurren a técnicas más avanzadas como el aprendizaje automático para poder analizar los diferentes aspectos del juego y poder obtener ventajas competitivas. Este enfoque permite interpretar el juego con mayor precisión y profundidad, apoyando decisiones estratégicas tanto dentro como fuera del campo.

El presente Trabajo de Fin de Grado se centra en el análisis del rendimiento en el fútbol profesional mediante el uso de técnicas de aprendizaje automático, con el objetivo de evaluar el impacto de diferentes métricas de tracking sobre el rendimiento colectivo de los equipos. En concreto, el análisis se ha realizado a nivel de selecciones nacionales, centrándose en partidos correspondientes a competiciones internacionales disputadas entre 2021 y 2024.

Adicionalmente, la base de datos utilizada es StatsBomb Open Data con acceso a numerosos partidos de varias competiciones del mayor nivel futbolístico actual. A partir de la cual obtenemos los datos de tracking que nos permiten realizar el análisis de rendimiento.

El desarrollo de este trabajo se ha realizado utilizando diferentes tecnologías, como entorno de desarrollo, se ha escogido Google Colaboratory. Además, el lenguaje de programación utilizado es Python, combinado con la importación de diferentes librerías reconocidas en el ámbito tecnológico del proyecto.

La primera fase del proyecto consistió en una fase de preprocesamiento en la que se seleccionaron las competiciones correspondientes, se realizó un análisis y limpieza de los datos disponibles y se construyó un conjunto de datos estructurado a partir de registros de eventos de partido. A partir de esta información, se generaron métricas relevantes que reflejan el comportamiento ofensivo, defensivo y de posesión de cada equipo en cada encuentro.

En segundo lugar, se llevó a cabo la fase de modelado, donde se implementaron diferentes algoritmos de aprendizaje automático basados en técnicas de análisis de datos predictivo. Obteniendo como resultado, el modelo superior al resto en términos de precisión y explicabilidad.

Posteriormente, se realizó el análisis de rendimiento mediante la utilización del mejor modelo de aprendizaje automático implementado. Para ello, se evaluó y explicó el impacto de las diferentes métricas personalizadas en el indicador de rendimiento definido, la diferencia de goles que existe en cada partido, diferenciando entre los dos equipos que lo disputan.

Finalmente, se exponen las conclusiones obtenidas tras la realización del proyecto, centrando el foco en los objetivos alcanzados y los resultados más relevantes del proyecto. Así como, la proposición de aspectos de mejora para futuros trabajos en el ámbito del análisis de rendimiento en el fútbol profesional.

Esta investigación ofrece una combinación de contribución académica y aplicación práctica, estableciendo una base para un campo en tendencia en la actualidad.

Abstract

In recent years, professional football has undergone a significant transformation due to the integration of technology across all aspects of the sport. The incorporation of tools such as data analysis has been essential in optimizing the performance of professional football teams. Beyond the intuition and experience of coaching staff, clubs and national teams are turning to more advanced techniques like machine learning to analyse various facets of the game and gain competitive advantages. This approach enables a deeper and more accurate understanding of the game, supporting strategic decision-making both on and off the pitch.

This Final Degree Project focuses on analysing performance in professional football through the application of machine learning techniques, with the objective of assessing the impact of different tracking metrics on teams' collective performance. Specifically, the analysis has been carried out at the national team level, focusing on matches from international competitions held between 2021 and 2024.

The dataset used comes from StatsBomb Open Data, which provides access to numerous matches from top-tier football competitions. From this source, we extract the tracking data necessary to conduct the performance analysis.

The development of this project was carried out using various technologies. Google Colaboratory was chosen as the development environment. In addition, the programming language used was Python, along with several well-known libraries relevant to the technological domain of the project.

The first stage of the project involved data preprocessing, which included selecting the relevant competitions, performing exploratory analysis and data cleaning, and constructing a structured dataset based on event records from each match. From this dataset, relevant metrics were generated to capture each team's offensive, defensive, and possession-related behaviour throughout the matches.

Next, the machine learning modeling phase was undertaken, during which multiple machine learning algorithms were implemented based on predictive data analysis techniques. This resulted in the identification of the model that performed best in terms of both accuracy and interpretability.

Subsequently, the performance analysis was conducted using the selected machine learning model. The impact of custom-designed metrics on the defined performance indicator—goal difference per match, distinguishing between the two competing teams—was evaluated and interpreted.

Finally, the conclusions drawn from the project are presented, highlighting the objectives achieved and the most relevant results. Additionally, proposals for improvement are offered for future work in the area of performance analysis in professional football.

This research offers a combination of academic contribution and practical application, laying the groundwork for a field that is currently gaining increasing relevance.

Tabla de contenidos

1	Introducción.....	1
1.1	Motivación.....	1
1.2	Objetivos del proyecto	2
1.3	Estructura de la memoria	2
2	Contenido y Alcance del proyecto.....	4
3	Estado del Arte	6
3.1	Análisis de datos	6
3.2	Aprendizaje automático.....	6
3.3	Análisis de datos en el fútbol profesional.....	7
3.4	Estudios similares.....	9
4	Tecnologías empleadas	11
4.1	Entorno de desarrollo.....	11
4.2	Lenguaje de programación y librerías	11
4.3	Base de datos.....	12
4.4	Datos de tracking.....	13
5	Desarrollo	15
5.1	Planteamiento	15
5.2	Preprocesamiento de datos.....	15
5.2.1	Dataset.....	16
5.2.2	Análisis Exploratorio de Datos	17
5.2.3	Limpieza de datos	19
5.3	Selección de variables y generación de métricas	20
5.4	Aprendizaje automático.....	25
5.4.1	Regresión lineal	26
5.4.2	Regresión Lasso.....	27
5.4.3	Regresión Ridge	28
5.4.4	Elastic Net	28
5.4.5	Regresión Lasso, Ridge y Elastic Net con validación cruzada	29
5.4.6	Regresión Random Forest	29
5.4.7	Random Forest mediante Grid Search y Randomized Search	30
5.4.8	Regresión XGBoost	31
5.4.9	XGBoost mediante GridSearch y RandomizedSearch	31
5.4.10	One-Hot Encoding.....	32
6	Resultados	33
6.1	Evaluación	33
6.2	Análisis de resultados	36
7	Conclusiones y Trabajo Futuro.....	40
8	Bibliografía	41

9	Anexos.....	43
----------	--------------------	-----------

1 Introducción

En la actualidad, el fútbol profesional no solo es el deporte más seguido a nivel mundial, sino también una industria predominante a nivel económico, que combina pasión, espectáculo y estrategia. Con millones de aficionados, financiación en crecimiento y una competición cada vez más exigente física y tácticamente, los clubes buscan constantemente nuevas formas de optimizar el rendimiento de sus jugadores y obtener ventaja competitiva. En este contexto, el uso de datos y tecnologías emergentes ha cobrado un protagonismo significativo.

Durante la última década, el análisis de datos ha transformado la forma en que se entiende y se gestiona el fútbol. Gracias al acceso a grandes volúmenes de información proveniente de sensores, sistemas de tracking y análisis de eventos, es posible analizar con precisión el comportamiento de los equipos durante un partido. Esta revolución de los datos ha impulsado a muchos clubes a adoptar técnicas de análisis avanzado para tomar decisiones más informadas, mejorar el rendimiento físico y táctico, y reducir el riesgo de lesiones.

Entre estas tecnologías, el aprendizaje automático destaca por su capacidad para detectar patrones complejos y realizar predicciones a partir de grandes conjuntos de datos. En lugar de limitarse a observaciones humanas o estadísticas simples, estos modelos permiten automatizar el análisis del juego y extraer conocimiento útil a partir de variables sutiles o no evidentes a simple vista. En consecuencia, su aplicación en el deporte profesional representa una oportunidad estratégica para optimizar el rendimiento de los jugadores y afinar decisiones técnicas.

En este primer capítulo se exponen las razones que motivaron la realización de este Trabajo de Fin de Grado, así como los objetivos planteados y la estructura general del resto de la memoria.

1.1 Motivación

Al iniciar la búsqueda de un tema para el Trabajo de Fin de Grado, se buscaba un proyecto que permitiera aplicar de manera práctica las competencias adquiridas a lo largo del grado, especialmente en áreas como el análisis de datos, la inteligencia artificial y la programación. El fútbol, siendo una pasión personal y un fenómeno global, ofrecía un contexto ideal para explorar la intersección entre la tecnología y el deporte.

En la actualidad, el análisis de datos ha transformado significativamente la forma en que se entiende y se juega al fútbol. Clubes profesionales utilizan técnicas avanzadas de análisis para optimizar el rendimiento de los jugadores, desarrollar estrategias tácticas y prevenir lesiones. El uso de datos de tracking y eventos, como los proporcionados por StatsBomb Open Data, permite una evaluación detallada del comportamiento de los jugadores en el campo, facilitando decisiones más informadas y precisas.

La motivación principal de este trabajo no es solo técnica, sino también práctica: demostrar cómo el aprendizaje automático puede proporcionar valor real en contextos altamente competitivos. Desarrollar un modelo capaz de evaluar el rendimiento deportivo con precisión no solo consolida los conocimientos

adquiridos durante el grado, sino que también responde a una necesidad concreta de la industria deportiva, donde cada detalle puede marcar la diferencia en el resultado final.

Debido a todo lo mencionado anteriormente, el desarrollo de un modelo de aprendizaje automático constituye un proyecto adecuado para un Trabajo de Fin de Grado no solo por tratarse de una temática de interés, sino que además permite demostrar las habilidades adquiridas durante el grado.

1.2 Objetivos del proyecto

El objetivo principal de este Trabajo de Fin de Grado es desarrollar un modelo de aprendizaje automático capaz de evaluar y cuantificar el impacto de métricas de tracking en el fútbol profesional, con el fin de analizar su influencia sobre el rendimiento de los jugadores en el terreno de juego. A través de este enfoque, se pretende demostrar cómo la tecnología puede aportar valor real en un entorno altamente competitivo, y cómo el análisis de datos puede transformar la manera en que se interpretan las actuaciones deportivas y se toman decisiones tácticas y estratégicas. Este objetivo se desglosa en los siguientes objetivos específicos:

- Recopilar y preprocesar datos de tracking provenientes de la base de datos StatsBomb Open Data, garantizando su limpieza, estructuración y adecuación para el análisis.
- Diseñar y entrenar modelos predictivos mediante técnicas de aprendizaje automático, capaces de identificar patrones relevantes en el rendimiento de los jugadores.
- Evaluar los modelos de aprendizaje automático utilizando métricas adecuadas de validación. Después, seleccionar el mejor de ellos para su utilización.
- Interpretar los resultados obtenidos para extraer conclusiones relevantes que puedan aplicarse a la optimización del rendimiento en fútbol profesional.

Estos objetivos no solo permitirán aplicar conocimientos adquiridos durante el grado en un contexto real, sino que también contribuirán a ilustrar el papel transformador que tiene el análisis avanzado de datos en el deporte moderno.

1.3 Estructura de la memoria

A continuación, se presenta la estructura de la memoria, con una descripción breve de cada uno de sus apartados.

- **Introducción:** se trata del apartado en el que se introduce la propuesta de trabajo, así como la motivación, los objetivos del proyecto y su estructura.

- **Contenido y alcance del proyecto:** se define el enfoque general del proyecto, detallando sus propósitos y limitaciones. También se expone el impacto potencial de los resultados y de su alcance.
- **Estado del arte:** se recopila información de diversos artículos de investigación y proyectos previos relacionados con el trabajo desarrollado, así como los fundamentos teóricos en los que se basa el proyecto, principalmente el análisis de datos y el aprendizaje automático.
- **Tecnologías empleadas:** en este apartado se describen las herramientas, lenguajes de programación, bibliotecas y entornos utilizados. Se justifica la elección de cada tecnología en función de las necesidades del proyecto.
- **Desarrollo:** se describe en detalle el procedimiento llevado a cabo para desarrollar el proyecto, abarcando desde la recopilación y el preprocesamiento de los datos, hasta el diseño, implementación y entrenamiento del modelo.
- **Resultados:** se presentan los resultados obtenidos a partir del modelo desarrollado. Se analiza su rendimiento y se interpretan los principales hallazgos en relación con los objetivos establecidos.
- **Conclusiones y trabajo futuro:** se presentan las conclusiones generales del proyecto, evaluando el grado de cumplimiento de los objetivos establecidos. Asimismo, se proponen posibles mejoras y futuras líneas de trabajo que podrían ampliarse o profundizarse.
- **Bibliografía:** se incluye el listado de todas las fuentes y referencias bibliográficas consultadas durante la realización del proyecto.
- **Anexos:** se incorporan materiales complementarios que apoyan el contenido del documento.

2 Contenido y Alcance del proyecto

El presente proyecto se enmarca en el ámbito del análisis de rendimiento en el fútbol profesional mediante la aplicación de técnicas de aprendizaje automático. Su principal objetivo ha sido construir un modelo predictivo que permita evaluar el impacto de diferentes métricas de juego sobre el rendimiento colectivo de los equipos, representado por la diferencia de goles en los partidos.

El enfoque adoptado se centra en el análisis colectivo, y no individual, del rendimiento, lo cual aporta una perspectiva táctica y estratégica más alineada con los intereses de equipos y cuerpos técnicos. Para ello, se ha centrado el análisis en selecciones nacionales y se han empleado datos de tracking obtenidos de la base StatsBomb Open Data, abarcando competiciones internacionales relevantes a nivel de selecciones entre 2021 y 2024. A partir de estos datos, se ha realizado un proceso riguroso de selección, limpieza, transformación y generación de nuevas métricas relevantes, divididas en categorías ofensivas, defensivas y de posesión.

El proyecto se ha desarrollado siguiendo una metodología estructurada en distintas fases:

- Recopilación y análisis exploratorio de datos: Se estudiaron las diferentes tablas disponibles y se seleccionaron aquellas competiciones actuales cuyos partidos cumplieran con criterios de vigencia y calidad.
- Diseño y definición de métricas personalizadas: Se generaron 14 métricas que reflejan aspectos tácticos clave, como la presión alta, la efectividad de los disparos, las pérdidas en campo propio o la posesión efectiva en zonas peligrosas.
- Creación de modelos mediante técnicas de aprendizaje automático para el análisis de datos: Se emplearon distintos modelos de regresión para predecir la diferencia de goles y la influencia de cada una de las métricas definidas.
- Evaluación del rendimiento de los diferentes modelos programados y generación de un informe que contiene la influencia de las diferentes métricas de juego en la variable objetivo junto a un análisis táctico del impacto de estas.

Este proyecto se enmarca en el creciente interés del fútbol profesional por incorporar herramientas basadas en datos para optimizar el rendimiento deportivo. Su alcance abarca tanto la dimensión técnica del modelado predictivo como la interpretación práctica de los resultados obtenidos. La elección de competiciones recientes y la utilización de una fuente de datos abierta y actualizable permiten, además, que el modelo sea escalable y replicable en nuevos contextos competitivos.

En cuanto a sus limitaciones, cabe destacar la disponibilidad restringida de datos, ya que las empresas que recopilan y almacenan este tipo de datos limitan considerablemente su acceso al gran público. Así como el hecho de que el análisis se ha realizado sobre partidos de selecciones, lo cual puede no representar completamente las dinámicas de clubes profesionales con mayor regularidad competitiva. No obstante, el enfoque metodológico puede adaptarse

fácilmente a otros contextos y bases de datos más completas si se dispusiera de acceso.

En definitiva, este trabajo no solo tiene un enfoque analítico, sino también aplicado, al buscar demostrar cómo el aprendizaje automático puede ser una herramienta poderosa en el análisis del rendimiento colectivo, facilitando decisiones basadas en evidencia y mejorando la comprensión táctica del juego.

3 Estado del Arte

El presente capítulo tiene como objetivo contextualizar teóricamente el trabajo realizado, presentando los fundamentos conceptuales y técnicos sobre los que se apoya el análisis llevado a cabo. Para ello, se recogen y describen las áreas claves para el proyecto dentro del marco del análisis de datos y del aprendizaje automático. Posteriormente se describe su aplicación específica en el ámbito del fútbol profesional.

3.1 Análisis de datos

En la actualidad, se almacenan infinitas cantidades de datos de forma digital que necesitan ser analizados para poder obtener información útil y convertirla en conocimiento accionable. Se entiende como el conjunto de técnicas, herramientas y procesos que permiten explorar, interpretar y visualizar la información contenida en esos datos, con el fin de descubrir patrones, tendencias, relaciones y comportamientos relevantes.

En este Trabajo de Fin de Grado, se emplean metodologías propias del análisis de datos para estudiar el rendimiento de equipos, identificando patrones que inciden en el éxito competitivo. Así, se demuestra cómo la integración de estas herramientas puede aportar valor real al ámbito del deporte de alto rendimiento, alineándose con las tendencias actuales del análisis de datos aplicado a contextos profesionales.

Existen diversos tipos de análisis de datos, cada uno diseñado para ofrecer respuesta a diferentes requerimientos de información y ofrecer distintos niveles de profundidad en la interpretación de los datos. En este caso, el proyecto se centra en un análisis predictivo [1]. Este tipo de análisis se enfoca en anticipar eventos futuros a partir del estudio de datos históricos. Mediante modelos de aprendizaje automático, se identifican patrones y tendencias que permiten realizar estimaciones con cierto grado de precisión, así como la evaluación del impacto de las diferentes métricas, objetivo principal del proyecto.

3.2 Aprendizaje automático

El aprendizaje automático (también conocido por el término “machine learning”) es una subdisciplina clave de la inteligencia artificial que permite a las máquinas aprender directamente de los datos sin necesidad de ser programadas de forma explícita para la tarea que deben abordar. A diferencia del software tradicional, utiliza algoritmos capaces de reconocer patrones y extraer conocimiento a partir de grandes volúmenes de datos, ajustando automáticamente sus predicciones a medida que se exponen a nueva información [2].

El aprendizaje automático forma parte natural del ecosistema del análisis de datos, ya que aprovecha los datos recopilados y procesados para generar modelos capaces de identificar patrones complejos, hacer predicciones y descubrir información valiosa. En el contexto de este proyecto, el aprendizaje automático constituye una herramienta clave para profundizar en el análisis del rendimiento de jugadores de fútbol profesional. A través de modelos de

aprendizaje automático, se busca identificar qué variables influyen de forma más significativa en el rendimiento de los equipos durante la competición. La integración de este proyecto sigue un enfoque supervisado.

Este enfoque se basa en utilizar conjuntos de datos etiquetados durante el proceso de entrenamiento. Es decir, cada entrada del conjunto de datos va acompañada de una salida conocida o "etiqueta" que representa la respuesta correcta o el resultado deseado (por ejemplo, una categoría, un valor numérico, o una clase). El modelo aprende a establecer relaciones entre las características de entrada y sus correspondientes salidas, permitiéndole realizar predicciones sobre nuevos datos similares [3].

Además, para llevar a cabo el análisis de los datos, se han empleado dos enfoques diferentes de modelado basados en técnicas de aprendizaje automático [4]: la regresión y los árboles de decisión. La regresión se utiliza principalmente para predecir valores continuos, permitiendo establecer relaciones cuantitativas entre una variable dependiente y una o varias variables independientes. Esta técnica resulta especialmente útil cuando se busca entender cómo influyen ciertos factores en una variable objetivo. Por otro lado, los árboles de decisión constituyen un método de modelado no lineal que organiza la información en una estructura jerárquica en forma de árbol, donde cada nodo representa una condición basada en los atributos de entrada, y las ramas conducen a distintas decisiones o clasificaciones.

3.3 Análisis de datos en el fútbol profesional

El fútbol profesional ha dejado de ser únicamente un deporte basado en el talento individual, la intuición táctica o la experiencia del cuerpo técnico. En la actualidad, se ha transformado en una disciplina de alto rendimiento donde el conocimiento derivado del análisis de datos adquiere un valor estratégico incuestionable. Cada acción sobre el terreno de juego, desde un lance del juego hasta una decisión táctica colectiva, puede ser cuantificada, interpretada y optimizada mediante tecnologías avanzadas. Este nuevo enfoque basado en datos permite abordar el juego desde una perspectiva objetiva, rigurosa y apoyada en evidencia, aportando una ventaja competitiva decisiva para clubes, entrenadores y cuerpos técnicos profesionales.

La transformación digital del fútbol se sostiene sobre dos pilares interdependientes: el análisis de datos y el aprendizaje automático. El primero actúa como la base operativa que permite convertir datos crudos, como registros de posicionamiento, secuencias de eventos, métricas fisiológicas o indicadores contextuales, en información estructurada, comprensible y visualizable. Esta información es crucial para la toma de decisiones tanto a corto como a largo plazo, ya sea durante una sesión de entrenamiento, en tiempo real durante un partido, o en procesos de planificación estratégica.

Por su parte, el aprendizaje automático aporta un nivel superior de análisis al automatizar la detección de patrones complejos, realizar predicciones y recomendar acciones optimizadas. A diferencia del análisis tradicional, basado en interpretaciones humanas o modelos estadísticos lineales, los algoritmos de aprendizaje automático permiten que el sistema "aprenda" de datos pasados, se adapte a contextos dinámicos y mejore su precisión de forma continua. En el entorno futbolístico, esta capacidad se traduce en ventajas como anticiparse al

comportamiento del rival, identificar factores ocultos que afectan al rendimiento, o automatizar tareas de scouting y análisis táctico.

Según el libro de *D. Link* [5]. El análisis de datos en fútbol profesional ha evolucionado hacia una estructura altamente sofisticada, basada en tres pilares fundamentales: datos de eventos, tracking y físicos:

- **Event data:** Recogen la cronología y tipo de acciones técnicas (pases, remates, faltas, entradas, asistencias...), estructuradas a menudo en formato codificado para permitir su análisis cuantitativo.
- **Tracking data:** Capturan la posición de los jugadores y del balón en intervalos muy breves de tiempo, normalmente mediante cámaras multicámara o sistemas GPS de alta precisión. Esto permite medir distancias recorridas, organización espacial o dinámica de formaciones.
- **Physical data:** Incluyen información biomecánica y fisiológica como velocidad, aceleración, carga cardíaca, tasa de recuperación o índices de fatiga.

Esta combinación de fuentes posibilita un análisis multidimensional del juego, en el que los aspectos técnicos, tácticos y físicos pueden abordarse de manera específica, permitiendo profundizar en dimensiones concretas del rendimiento, como se desarrollará en este proyecto, o bien integrarse de forma conjunta en una narrativa analítica global que facilite la optimización integral de todos los indicadores de rendimiento del equipo.

Desde una perspectiva más aplicada, destaca cómo la integración de tecnologías como GPS, cámaras de vídeo 360° o sensores biométricos ha transformado el trabajo de los cuerpos técnicos y analistas. Gracias al big data, los entrenadores pueden acceder a informes detallados y en tiempo real que analizan el esfuerzo de cada jugador, su desempeño táctico y sus áreas de mejora. Esto permite tomar decisiones más informadas no solo durante el entrenamiento, sino también durante el desarrollo de los partidos, optimizando la estrategia en función del análisis cuantitativo [6].

También cabe destacar la capacidad predictiva que ofrece el análisis de grandes volúmenes de datos en este contexto [7]. A través del uso de modelos de aprendizaje automático, se puede estimar la probabilidad de que una acción acabe en gol, detectar fatiga antes de que aparezcan síntomas visibles, o incluso anticipar patrones tácticos del equipo rival. Este uso estratégico de la información permite transformar el enfoque reactivo tradicional por uno proactivo y automatizado, donde las decisiones se sustentan en evidencias empíricas.

En definitiva, el análisis de datos en el fútbol profesional se ha consolidado como un eje fundamental del rendimiento competitivo. Su integración con herramientas de aprendizaje automático no solo amplifica la capacidad de entender el juego, sino que redefine la manera de entrenar, competir y planificar. Ya no se trata únicamente de observar lo que ocurre en el campo, sino de comprender por qué ocurre y qué es probable que ocurra después. En este contexto, el presente proyecto se inserta plenamente dentro de esta tendencia de innovación, al buscar desarrollar un modelo que analice e interprete automáticamente los factores clave del rendimiento, contribuyendo así al avance de un enfoque más científico y basado en datos dentro del fútbol profesional.

3.4 Estudios similares

El creciente interés por aplicar inteligencia artificial y aprendizaje automático al ámbito deportivo ha impulsado una producción científica cada vez más especializada. En particular, el fútbol profesional ha sido objeto de múltiples investigaciones centradas en analizar y predecir el rendimiento de los jugadores y equipos mediante técnicas avanzadas de análisis de datos. Este apartado recoge algunos de los estudios más representativos que guardan relación directa con los objetivos del presente trabajo.

Uno de los artículos investigativos más completos y que sirvió como base para orientar este proyecto es el titulado "*Machine learning application in soccer: a systematic review*" [8]. Este estudio presenta una revisión sistemática de 32 investigaciones científicas contemporáneas y relevantes centradas exclusivamente en la aplicación de modelos de aprendizaje automático al fútbol. Las publicaciones analizadas se agrupan en tres grandes áreas: prevención de lesiones, análisis del rendimiento y detección de talento.

Dentro del bloque de rendimiento, que agrupa la mayoría de los estudios revisados, se abordan aspectos tan diversos como la predicción de resultados de partidos, el análisis del rendimiento técnico y táctico, así como el seguimiento de parámetros físicos y fisiológicos de los jugadores. La revisión destaca la utilidad de algoritmos como árboles de decisión, redes neuronales, SVM y modelos de clasificación, utilizados para anticipar comportamientos de juego, segmentar perfiles de jugador o evaluar el impacto de distintas variables en el resultado deportivo.

En el área de prevención de lesiones, los modelos predictivos se aplican al monitoreo de cargas de entrenamiento y condiciones fisiológicas para anticipar posibles lesiones musculares. En cambio, los estudios centrados en la detección de talento se enfocan en identificar, a partir de métricas objetivas, a jóvenes promesas con un alto potencial de desarrollo, reduciendo el sesgo subjetivo de los métodos tradicionales de captación de talento.

El estudio concluye subrayando que, si bien los resultados obtenidos hasta ahora son prometedores, existen ciertos desafíos metodológicos que deben ser abordados para lograr una mayor generalización y fiabilidad de los modelos. Entre ellos, se mencionan la necesidad de utilizar conjuntos de datos más amplios, representativos y variados, así como garantizar una validación rigurosa de los modelos aplicados.

Este trabajo representa una referencia clave dentro del estado del arte, ya que ofrece una visión panorámica y estructurada del uso del aprendizaje automático en el fútbol profesional, identificando las principales líneas de investigación existentes y los retos aún pendientes. Asimismo, aporta un marco de comparación valioso para contextualizar el presente proyecto dentro de las tendencias actuales del análisis de datos aplicados al rendimiento deportivo.

A continuación, nos centraremos en algunos trabajos específicos en el área de rendimiento dentro del fútbol profesional, y en concreto en el rendimiento colectivo, es decir, el rendimiento de los equipos profesionales como hace este proyecto. En primer lugar, es fundamental destacar el estudio de Fernández y Bornn (2018), titulado "Wide Open Spaces: Statistical Analysis of Spatial Metrics in Soccer". Este trabajo introduce un marco metodológico innovador para el análisis del rendimiento colectivo, poniendo especial énfasis en las métricas espaciales derivadas del posicionamiento de los jugadores. Los autores

proponen que la comprensión del juego debe ir más allá de los eventos aislados (pases, tiros, recuperaciones) y centrarse en cómo los equipos generan, ocupan y aprovechan el espacio en el campo [9].

Utilizando datos de seguimiento posicional, el artículo analiza cómo los equipos crean “espacios abiertos”, zonas del terreno de juego donde un jugador puede recibir el balón con ventaja y cómo estas zonas se relacionan con la generación de ocasiones de gol. Se cuantifica el valor ofensivo de determinadas configuraciones espaciales, ofreciendo así una medida más compleja y contextualizada del rendimiento ofensivo colectivo. Esta perspectiva ha contribuido significativamente a redefinir el análisis del fútbol desde un enfoque más dinámico y táctico, donde la organización y el movimiento conjunto del equipo cobran una relevancia central.

En segundo lugar, el artículo de Lago-Peñas et al., “The influence of tactical and performance variables on winning in football”, adopta una perspectiva estadística para identificar las variables de rendimiento que más influyen en el resultado de los partidos [10]. A partir del análisis de más de 300 partidos de competiciones profesionales, el estudio examina cómo variables como la posesión del balón, la eficacia en las transiciones ofensivas y defensivas, el número de tiros a puerta, las recuperaciones en zonas adelantadas o el número de pases completados se correlacionan con una mayor probabilidad de victoria.

Este trabajo es especialmente relevante porque demuestra empíricamente cómo determinadas métricas, tanto ofensivas como defensivas, tienen un peso cuantificable en el éxito de los equipos. Además, refuerza la importancia de evaluar el rendimiento desde una perspectiva colectiva, considerando las interacciones tácticas y no solo el rendimiento individual de los jugadores. Su enfoque riguroso y basado en datos establece una base sólida para la comparación entre equipos y la predicción de resultados en función de variables observables durante el juego.

Ambos estudios han tenido un impacto significativo en el diseño del presente proyecto, especialmente en la decisión de enfocar el análisis en el impacto de diferentes métricas de rendimiento colectivo sobre los resultados competitivos. La propuesta de Fernández y Bornn aportó una nueva forma de entender el valor espacial y táctico del juego, mientras que el trabajo de Lago-Peñas et al. proporcionó un modelo cuantitativo claro sobre cómo determinadas variables inciden en la victoria. Estos enfoques, especialmente el segundo, han servido como inspiración metodológica, guiando la construcción de un análisis orientado a identificar qué indicadores tienen un mayor peso en el rendimiento general de los equipos profesionales de fútbol tomando el resultado de los partidos como indicador de éxito.

4 Tecnologías empleadas

Para la implementación del presente trabajo se han utilizado herramientas para poder desarrollar el procesamiento de datos y el modelo de aprendizaje automático. A continuación, se describen el entorno de desarrollo, el lenguaje de programación, la base de datos y las principales bibliotecas utilizadas.

4.1 Entorno de desarrollo

Google Collaboratory, también conocido como Google Colab, es una plataforma basada en la nube que ofrece un entorno de programación mediante Jupyter Notebooks que permiten programar sin necesidad de instalación local, mejorando la accesibilidad y portabilidad del proyecto.

Este entorno de desarrollo nos ofrece numerosas ventajas, la plataforma proporciona acceso a unidades de procesamiento gráfico (GPU) y unidades de procesamiento tensorial (TPU), que son indispensables para poder optimizar el procesamiento de grandes cantidades de datos y el entrenamiento de modelos de aprendizaje automático, como las utilizadas en este proyecto. Gracias a esto, se aceleran considerablemente los procesos computacionales que requieren alta demanda mejorando en términos de rendimiento a un entorno local. También nos permite gestionar y almacenar diferentes secciones del proyecto gracias a su integración con Google Drive.

En cuanto a su compatibilidad, Google Collaboratory permite la utilización de herramientas ampliamente reconocidas en los ámbitos del análisis de datos y del aprendizaje automático [11]. Además, su interfaz organizada en Notebooks brinda una gran experiencia de programación gracias a su reproducibilidad y claridad. Debido a lo cual se facilita la realización del proyecto comparado con otros entornos de desarrollo como VS Code que permiten una mayor personalización, pero pueden derivar en problemas con la configuración del entorno, la gestión de dependencias y la capacidad de computación.

4.2 Lenguaje de programación y librerías

En la actualidad, Python se ha posicionado como uno de los lenguajes de programación más empleados a nivel global, tanto a nivel profesional como académico. Según el índice TIOBE, Python ocupar el primer puesto en popularidad gracias a su versatilidad y facilidad de aprendizaje [12], superando a otros como Java o C++.

Python ha demostrado una gran fortaleza en el análisis de datos y en el aprendizaje automático gracias a su ecosistema de bibliotecas especializadas. Podemos destacar Pandas para el procesamiento de datos, NumPy para cálculos numéricos, Seaborn para visualización, y scikit-learn o TensorFlow para el desarrollo de modelos de aprendizaje automático.

En el ámbito particular del análisis de rendimiento en el fútbol profesional, Python es una herramienta de gran utilidad, sirviendo como herramienta para procesar grandes volúmenes de datos de partidos, analizar patrones tácticos o predecir resultados. Plataformas populares especializadas en análisis deportivo

como Opta, Wyscout o StatsBomb disponen repositorios con bases de datos compatibles con este lenguaje lo que favorece el uso de este en el mundo del fútbol [13].

Por tanto, la elección de Python como lenguaje de programación para este proyecto se debe a su liderazgo en ciencia de datos y aprendizaje automático, así como sus aplicaciones en el ámbito deportivo, lo cual se alinea con los propósitos del trabajo.

Para el desarrollo del presente trabajo, se han empleado un conjunto de librerías de Python que permiten procesar, visualizar y analizar datos de forma eficiente, así como aplicar modelos de aprendizaje automático para evaluar el rendimiento de los equipos en el ámbito del fútbol. Han sido fundamentales para implementar las diferentes etapas del análisis, a continuación, se detallan las librerías utilizadas:

- **Pandas:** Librería esencial para la manipulación y análisis de datos estructurados. Permite cargar, transformar y explorar datasets, facilitando tareas como el filtrado, la agrupación o el tratamiento de valores nulos.
- **NumPy:** Complementaria a Pandas, proporciona soporte para cálculos matemáticos de alto rendimiento.
- **scikit-learn (sklearn):** Uno de los paquetes más utilizados para la implementación de modelos de aprendizaje automático. Se ha empleado para dividir los datos en conjuntos de entrenamiento y prueba, realizar validación cruzada, ajustar hiperparámetros y entrenar distintos modelos. También ha sido clave para evaluar el rendimiento de los modelos mediante diferentes métricas.
- **XGBoost:** Librería optimizada para el aprendizaje automático basada en árboles de decisión, especialmente útil en competiciones y análisis con grandes volúmenes de datos.
- **Matplotlib.pyplot y Seaborn:** Herramientas de visualización que proporcionan control detallado sobre la creación de gráficos. Se han utilizado complementariamente para generar visualizaciones personalizadas en distintas etapas del análisis.

4.3 Base de datos

Previo al inicio del desarrollo de este proyecto fue necesario explorar las diferentes bases de datos disponibles para asegurar la viabilidad de este. Examinando las principales bases de datos de tracking de fútbol, destacan por su relevancia y calidad: Second Spectrum, StatsBomb y Opta Data Vision.

Comenzando con Second Spectrum [14], ofrece un tracking de altísima resolución, generando más de 1 millón de datos por partido, al capturar la posición del balón y de todos los jugadores 25 veces por segundo, pero su acceso está restringido a entidades profesionales como clubes y federaciones. Es el proveedor oficial para ligas profesionales como la Premier League o la MLS.

En segundo lugar, StatsBomb [15] también está destinado a entidades

profesionales y con un volumen estimado de 3,000 eventos detallados por partido, incluyendo información contextual lo que lo convierte en uno de los conjuntos de datos más ricos, un poco por debajo del anterior. Además, permite el acceso a parte de su contenido mediante StatsBomb Open Data de forma gratuita para cualquier usuario.

Por último, Opta Vision [16] proporciona datos de tracking continuo para los 22 jugadores en el campo, permitiendo análisis tácticos y físicos de alta precisión mediante un sistema que combina recolección manual experta con tecnologías de visión por computadora e inteligencia artificial para generar datos detallados de eventos y tracking en tiempo real.

En todas estas bases de datos disponemos de contenido de alta calidad ya que tenemos acceso a grandes volúmenes de datos pertenecientes a competiciones del más alto nivel. En contraste, existe una barrera de acceso considerable, ya que todos estos conjuntos de datos están diseñados como parte de servicios exclusivos dirigidos a clubes profesionales y organizaciones con altos recursos.

Finalmente, debido a su accesibilidad y la calidad de sus datos, se ha elegido como fuente de datos para este proyecto a StatsBomb Open Data, una iniciativa de la empresa Hudl StatsBomb, reconocida por su liderazgo en el análisis de datos deportivos, especialmente en el ámbito del fútbol. Esta plataforma pone a disposición del público un conjunto amplio y detallado de datos de competiciones nacionales e internacionales, con el objetivo de fomentar la investigación y el desarrollo de proyectos relacionados con el análisis del rendimiento futbolístico. Además, cabe destacar que el contenido gratuito disponible permite acceso a competiciones de la mayor relevancia y actualidad como el Mundial 2022 o la Eurocopa 2024, lo que favorece a que el proyecto está alineado con la actualidad del deporte y también pueda incorporar nuevos datos en el futuro manteniéndose actualizado.

El repositorio de StatsBomb Open Data [17] se encuentra disponible en GitHub y ofrece acceso a los datos en tres formatos distintos: como archivos JSON obtenidos a través de la StatsBomb Data API, como paquete para R, y como librería para Python. Esta última opción ha sido la utilizada en el presente trabajo, ya que permite acceder de forma sencilla a los datos desde el entorno de desarrollo, facilitando su análisis mediante la importación directa de la librería correspondiente.

4.4 Datos de tracking

En el fútbol profesional moderno, los datos de tracking han adquirido un papel central en el análisis del rendimiento colectivo e individual. Estos datos, también conocidos como datos de seguimiento posicional, consisten en el registro continuo de la ubicación exacta de los jugadores y del balón a lo largo del tiempo durante un partido. Generalmente, se obtienen mediante tecnologías como sistemas de cámaras multicámara, sensores GPS o tecnologías ópticas de seguimiento automatizado. Gracias a este seguimiento, es posible registrar con precisión todas las acciones de juego que suceden durante un partido de fútbol profesional.

Según Big Data Sports [18], los datos de tracking representan uno de los mayores avances del análisis aplicado al fútbol, ya que permiten traducir dinámicas complejas del juego en información cuantificable y procesable. El verdadero valor de estos datos radica en su transformación en métricas

comprensibles, visualizaciones intuitivas y narrativas útiles para entrenadores, analistas y cuerpos técnicos.

Este tipo de información espaciotemporal permite ir más allá del análisis basado en eventos aislados (como pases, tiros o recuperaciones), abriendo la puerta a una comprensión profunda del comportamiento táctico y posicional de los equipos. A partir de los datos de tracking se pueden calcular métricas avanzadas como la ocupación del espacio, la presión coordinada, el control posicional y el desplazamiento colectivo. Además, podemos seguir definiendo métricas más básicas como porcentaje de acierto de diferentes tipos de eventos con mayor precisión. Estas métricas generadas a partir de datos de tracking son fundamentales para la construcción de modelos de inteligencia artificial que buscan evaluar el rendimiento, predecir comportamientos o identificar ventajas tácticas.

En el marco de este proyecto, se reconoce la relevancia esencial de los datos de tracking como base teórica y metodológica. Esencialmente, estos datos sustentan las variables consideradas para el análisis posterior, ya que reflejan los diferentes tipos de acciones que suceden a lo largo de un partido de fútbol profesional.

5 Desarrollo

En este apartado comienza con el planteamiento del trabajo que se va a realizar. Después, se recoge el proceso llevado a cabo para transformar los datos brutos en un modelo de aprendizaje automático capaz de analizar el rendimiento colectivo en el fútbol profesional. El desarrollo se ha estructurado en distintas fases, desde la obtención y preparación de los datos hasta la aplicación de técnicas de aprendizaje automático. Cada una de estas etapas ha sido diseñada y ejecutada con el objetivo de generar un conjunto de métricas significativas y construir un modelo interpretativo alineado con los objetivos del proyecto.

5.1 Planteamiento

Antes de abordar el desarrollo técnico del proyecto, es fundamental establecer con claridad la solución propuesta. El presente trabajo se enmarca en el ámbito del aprendizaje automático aplicado al análisis de datos, abordando específicamente un problema de regresión supervisada.

El planteamiento consiste en: dado un conjunto de datos de eventos y tracking correspondientes a partidos internacionales de selecciones, procesar y transformar esa información en un conjunto de métricas personalizadas agregadas por equipo y partido. Estas métricas describen diferentes aspectos del comportamiento táctico de los equipos, clasificados en tres dimensiones: ofensiva, defensiva y de posesión.

A partir de estas métricas explicativas, se entrenan diferentes modelos de aprendizaje automático usando regresión y árboles de decisión, cuyo objetivo es predecir la diferencia de goles obtenida por cada equipo en cada partido, entendida como una medida cuantitativa del rendimiento colectivo.

Este enfoque no solo permite estimar el rendimiento con técnicas predictivas, sino también analizar e interpretar qué métricas tienen mayor influencia en el resultado final.

5.2 Preprocesamiento de datos

El preprocesamiento de datos constituye una etapa clave para garantizar la posterior utilidad del conjunto de datos que sirve de base para un proyecto de análisis basado en aprendizaje automático. Para este trabajo, el objetivo ha sido convertir los datos proporcionados por StatsBomb Open Data en un conjunto de datos estructurado y alineado con los objetivos del proyecto. En concreto se ha desarrollado en varias fases concretas:

- **Análisis y limpieza:** aunque la base de datos de StatsBomb ya presenta una alta calidad. Se comenzó con un análisis exploratorio de los datos disponibles, después se verificó que los datos a utilizar no contuvieran valores nulos, duplicados ni inconsistencias. También se descartaron durante todo el proceso las variables que no aportaban valor al análisis, como identificadores internos, alineaciones o metadatos irrelevantes, centrándose únicamente en aquellas variables útiles para el modelado.

- **Selección de partidos:** se filtraron exclusivamente los partidos de selecciones nacionales correspondientes a las siguientes competiciones: Eurocopa 2020, Mundial 2022, Copa África 2023, Copa América 2024 y Eurocopa 2024. Esto dio lugar a un total de 250 partidos válidos para el análisis.
- **Extracción de eventos:** a partir de esos partidos se extrajeron 878.417 eventos registrados en la base de datos, representando la totalidad de acciones de juego relevantes.
- **Estructuración de datos:** los eventos fueron agrupados por equipo y partido, y procesados en estructuras de tipo dataframe. Este proceso facilitó el manejo del dataset y la generación de las métricas necesarias.
- **Generación de métricas:** a partir del dataframe, se generaron las métricas de juego necesarias para el análisis y se construyó un dataframe final con la única información relevante para el análisis de rendimiento.

En resumen, gracias al preprocesamiento, se ha podido transformar la base de datos original en un dataset final estructurado con 500 filas (un registro por equipo y partido) y 17 columnas: una variable objetivo (*goal_diff*) y 16 métricas personalizadas que resumen el comportamiento colectivo del equipo durante cada encuentro. Este dataset constituye la base del análisis predictivo desarrollado en las siguientes fases.

5.2.1 Dataset

En primer lugar, es necesario describir el conjunto de datos disponible que se ha empleado como base para el análisis. Como se ha mencionado con anterioridad, la base de datos procede de la plataforma StatsBomb Open Data, de gran relevancia en el ámbito del fútbol profesional. Esta base de datos registra y almacena información detallada sobre todos los eventos (datos de tracking, acciones del juego y metainformación del partido) que ocurren durante un partido de fútbol profesional.

El dataset está organizado en cuatro tablas principales, cada una de ellas incorpora identificadores para cada una de sus entradas. La tabla *competitions*, contiene la información sobre las competiciones disponibles, cada fila se corresponde a una competición y sus columnas contienen información descriptiva sobre la misma, por ejemplo, el nombre, la temporada o la localización. Además, esta tabla tiene un '*competition_id*' y un '*season_id*' para poder relacionarse con la tabla *matches*.

La tabla *matches*, contiene la totalidad de los partidos albergados en la base de datos, gracias a los identificadores de la competición, se puede acceder a los partidos disputados en una competición concreta, ya que cada partido tiene como atributos: la competición y la temporada. Esta tabla, también dispone de su propio identificador, '*match_id*', y da información acerca del partido, como el resultado, los equipos o el estadio en el que se disputa.

También existe la tabla *events*, que contiene todos los eventos disponibles y se relaciona con la tabla de partidos ya que tiene como atributo el partido al que corresponde cada evento. La tabla *events* es la más extensa, ya que cada

columna hace referencia a un tipo de evento, pero cada evento suele ser de un único tipo, por lo que cada fila alberga prácticamente todas las columnas con valores nulos. Las columnas de los eventos pueden ser información sobre pases, tiros, posiciones de los jugadores u otras acciones del juego. Al igual que en las otras tablas, existe un identificador 'id' para cada evento.

En conjunto, la base de datos original ofrece una estructura jerárquica y relacional, en la que cada competición contiene múltiples partidos, y cada partido múltiples eventos y alineaciones. Esto facilita la generación de métricas agregadas por equipo y partido, tal como se ha llevado a cabo en este proyecto.

Además, en esta base de datos existen dos tipos de datos, los datos de tracking clásicos, que se han usado en este proyecto, y los datos 360°, que se han comenzado a implementar recientemente pero todavía no hay suficientes para realizar un análisis adecuado.

Por último, está disponible la tabla *lineups*, que contiene información sobre las alineaciones de los partidos, pero no se ha empleado en el presente trabajo ya que no es de utilidad.

Por otra parte, cabe destacar la previa comprensión del manual del que dispone la base de datos StatsBomb Open Data, que ha servido para poder entender como está estructurada la propia base de datos.

5.2.2 Análisis Exploratorio de Datos

El análisis exploratorio de datos o “EDA” es una etapa fundamental dentro del preprocesamiento, nos permite observar la estructura del conjunto de datos disponible, entender las relaciones que existen entre las diferentes variables y poder detectar distribuciones no uniformes. Por tanto, el análisis exploratorio de datos nos ofrece una visión inicial y descriptiva del comportamiento de los datos, sirviendo como referencia para una correcta toma de decisiones durante el resto del proyecto.

Para el presente proyecto, el análisis exploratorio de datos se ha centrado en examinar las principales métricas disponibles en el conjunto de datos, fijándose especialmente en su distribución. Además, ha sido de gran ayuda para comprender las conexiones existentes entre los diferentes tipos de datos existentes. Tras la correcta importación de los datos, se procede a su estudio. Se puede apreciar que los datos están adecuadamente estructurados, facilitando su análisis y preprocesado.

En primer lugar, disponemos de treinta variables distintas que tienen diversas funciones internas, pero solo podemos acceder a cuatro tipos distintos de datos: *competitions*, *matches*, *lineups* y *events*. Estos datos hacen referencia al conjunto de competiciones disponibles, los partidos disputados en estas competiciones, las alineaciones registradas durante estos partidos y por último todos los datos de tracking recogidos y almacenados durante los partidos, denominados eventos. Se ha descartado el uso de alineaciones ya que el objetivo del trabajo es poder analizar el rendimiento colectivo de los equipos por lo que no es necesario conocer que jugadores realiza cada evento, sino que agruparemos las variables que seleccionemos en función de los diferentes equipos existentes.

En el apartado de competiciones, podemos apreciar que hay disponibles 74 competiciones distintas. Las competiciones se almacenan en una tabla que

contiene 12 columnas, de las cuales 2 *bool*, 2 *int64* y 8 *object* (Los *object* en Python son la base para cualquier clase). Profundizando en los tipos *object*, 4 se corresponden a *string* con atributos sobre las competiciones y las otras 4 se corresponden a los último partidos actualizados y disponibles, también como *string* a modo de referencia o “id”. En cuanto a valores nulos, existen 86 valores nulos entre dos columnas: ‘*match_update_360*’ y ‘*match_available_360*’ (recopilan los eventos de los partidos mediante una cámara 360°, no se usarán en este proyecto).

Datos en competitions			
Columna	Tipo de dato	Valores no nulos	Total de valores
competition_id	int64	74	74
season_id	int64	74	74
country_name	object	74	74
competition_name	object	74	74
competition_gender	object	74	74
competition_youth	bool	74	74
competition_international	bool	74	74
season_name	object	74	74
match_updated	object	74	74
match_updated_360	object	56	74
match_available_360	object	10	74
match_available	object	74	74

Figura 5.1: Información de la tabla “competitions”.

En el apartado de partidos, disponemos de un total de 3433 partidos. Se puede apreciar que cada partido conforma una tabla que contiene 22 columnas, 4 de tipo *int64* y 18 *object*. Profundizando en los tipos *object*, todos se corresponden a *string* que aportan diferente información o referencias a datos sobre un partido. Los valores nulos existentes no son de gran relevancia para este trabajo.

Datos en matches			
Columna	Tipo de dato	Valores no nulos	Total de valores
match_id	int64	3433	3433
match_date	object	3433	3433
kick_off	object	3428	3433
competition	object	3433	3433
season	object	3433	3433
home_team	object	3433	3433
away_team	object	3433	3433
home_score	int64	3433	3433
away_score	int64	3433	3433
match_status	object	3433	3433
match_status_360	object	3433	3433
last_updated	object	3433	3433
last_updated_360	object	1797	3433
match_week	int64	3433	3433
competition_stage	object	3433	3433
stadium	object	3423	3433
referee	object	3233	3433
home_managers	object	3433	3433
away_managers	object	3433	3433
data_version	object	3431	3433
shot_fidelity_version	object	3235	3433
xy_fidelity_version	object	3189	3433

Figura 5.1: Información de la tabla “matches”.

En el apartado de eventos, disponemos de aproximadamente 12 millones de eventos en total. Se puede apreciar que cada evento conforma una tabla que contiene 89 columnas, 8 *float64*, 8 *int64* y 73 *object*. Profundizando en los tipos de *object*. Profundizando en los tipos *object*, todos se corresponden principalmente a valores *string* o *boolean*. Los eventos son fundamentales para poder generar las métricas necesarias, por ello hay que profundizar en los diferentes tipos que existen: 'Starting XI', 'Half Start', 'Pass', 'Ball Receipt', 'Carry', 'Clearance', 'Ball Recovery', 'Shot', 'Block', 'Goal Keeper', 'Miscontrol', 'Pressure', 'Duel', 'Interception', 'Foul Committed', 'Foul Won', 'Dispossessed', 'Dribble', 'Dribbled Past', 'Error', 'Injury Stoppage', 'Half End', 'Substitution', 'Bad Behaviour', 'Referee Ball-Drop', 'Tactical Shift', 'Player Off', 'Player On', 'Shield'. Como cada fila de la tabla, es decir, cada evento, puede ser de uno o varios de los diferentes tipos, pero contiene información sobre todos, existen valores nulos en las columnas que no se corresponden con los tipos que representa cada evento en específico. Además, debido a la gran cantidad de columnas, no se adjunta la figura con la información detallada.

5.2.3 Limpieza de datos

La limpieza de datos es una etapa fundamental en cualquier proceso de análisis, cuyo objetivo es garantizar la calidad, consistencia y fiabilidad de los datos utilizados. Consiste en identificar y corregir errores, eliminar duplicados, tratar valores nulos o atípicos, y transformar los datos a formatos coherentes con el

análisis posterior. Esta fase resulta clave para evitar sesgos, mejorar la precisión de los modelos y asegurar la validez de los resultados.

En este proyecto, sin embargo, no se ha llevado a cabo una fase de limpieza de datos convencional, ya que el enfoque adoptado ha sido distinto. Dado que la base original contiene una gran cantidad de datos provenientes de múltiples competiciones, tipos de eventos y registros, muchos de los cuales no son directamente útiles para los objetivos de este proyecto, se ha optado por avanzar directamente a la fase de selección de variables.

En esta fase se han identificado y construido únicamente aquellas métricas relevantes para el análisis del rendimiento colectivo, descartando el resto. Como parte de este proceso, se ha verificado que las variables seleccionadas no contienen valores nulos, inconsistentes o duplicados, lo cual garantiza su validez para el posterior modelado sin necesidad de una limpieza generalizada del conjunto completo de datos.

5.3 Selección de variables y generación de métricas

Esta fase tiene como objetivo identificar los atributos más relevantes para el análisis del rendimiento colectivo de los equipos, así como construir nuevas variables derivadas que ofrezcan una visión más completa, contextualizada y significativa del juego. La selección de variables no se ha limitado únicamente a aquellas disponibles en el conjunto original de datos, sino que ha implicado un proceso de transformación y combinación de campos para generar indicadores más representativos de la dinámica táctica y del comportamiento de los equipos durante la competición. Esta estrategia permite adaptar los datos a los objetivos concretos del proyecto, orientados a evaluar el impacto de diferentes factores en el rendimiento global de los equipos. Durante este proceso, se han tenido en cuenta criterios tanto técnicos como conceptuales: la disponibilidad y completitud de los datos, su coherencia con los modelos de aprendizaje automático, y su valor interpretativo en el contexto del fútbol profesional. Asimismo, se ha verificado que las variables seleccionadas estén libres de valores nulos y presenten una distribución adecuada para su análisis posterior.

En primer lugar, se han seleccionado las competiciones de las que extraer los datos. Debido a que el fútbol ha evolucionado significativamente como deporte desde su origen a la actualidad, no tiene sentido analizar datos antiguos. Por tanto, se ha decidido analizar todos los partidos posteriores al último cambio de reglamento que hubiera tenido un gran impacto en todos los ámbitos del juego.

Según recoge el artículo: “El fútbol se reinventa: las nuevas reglas y cómo la tecnología y el Covid han influido en los cambios” [19], durante la pandemia de COVID-19, la IFAB ratificó varias modificaciones permanentes que redefinieron la estructura y el ritmo del juego. Entre estas destacan: la adopción definitiva de cinco sustituciones por equipo, ajustes en la normativa de penaltis para porteros y la introducción del video arbitraje (VAR). Estos cambios han alterado de forma sustancial la gestión de la táctica y gestión de los equipos, influyendo directamente en métricas relevantes de rendimiento. Debido a ello, se utilizan para este trabajo las competiciones a nivel de selecciones, disponibles en la base de datos, disputadas entre 2021 y 2024. En concreto, son las 5 siguientes: “Eurocopa 2020” (disputada en 2021), “Copa Mundial 2022”, “Copa África 2023”, “Copa América 2024” y “Eurocopa 2024”. En consecuencia, se han almacenado

en un mismo dataframe(*matches*) todos los partidos incluidos en dichas competiciones, obteniendo un total de 250 partidos. A partir de estos partidos específicos, se ha almacenado en otro dataframe(*events*) el conjunto de eventos correspondientes, obteniendo un total de 878417 eventos seleccionados para el análisis.

La primera variable por definir es la variable objetivo, a partir de esta variable podremos entrenar los modelos de aprendizaje automático y extraer estadísticas e información relevante. El objetivo del proyecto es analizar el rendimiento de los equipos, el fútbol como cualquier deporte mide el rendimiento por resultados, es decir, victorias, empates y derrotas. Sin embargo, se ha seleccionado la diferencia de goles (definida como la resta entre los goles del equipo local y del visitante, o viceversa), ya que permite captar matices importantes sobre el rendimiento en el partido, como si una victoria o derrota fue ajustada o muy amplia. Este nivel de detalle en la variable objetivo es especialmente valioso al analizar el rendimiento colectivo, ya que proporciona una medida más proporcional al desempeño observado. Para definir la diferencia de goles, en la tabla *matches* calculamos la diferencia de goles tanto para el equipo local como visitante generando dos nuevas columnas y eliminamos todas las columnas no útiles, quedando: *match_id*, *home_team*, *away_team*, *home_score*, *away_score*, *goal_diff_home* y *goal_diff_away*.

En segundo lugar, se han definido las métricas de juego personalizadas, diseñadas específicamente para capturar aspectos del rendimiento colectivo que no están directamente representados en los datos originales. Estas métricas buscan reflejar con mayor precisión el comportamiento táctico, la eficacia ofensiva y defensiva, así como la capacidad del equipo para generar situaciones de peligro o controlar el desarrollo del partido. Gracias a este trabajo de definición, podremos proporcionar la influencia que tienen dichas métricas en el rendimiento de los equipos, es decir la implicación que tiene cada métrica personalizada en la variable objetivo, la diferencia de goles.

El proceso de diseño de estas métricas ha combinado criterios tanto cuantitativos como cualitativos, basándose en el conocimiento contextual del juego. En muchos casos, las métricas se han generado mediante la combinación o transformación de variables originales (como totales, promedios o proporciones), mientras que en otros casos se han construido a partir de reglas específicas que reflejan situaciones relevantes del juego (por ejemplo, eficacia en duelos, efectividad en zonas clave, ratio de acciones ofensivas por posesión, entre otras). Las situaciones de juego en el fútbol pueden dividirse en tres tipos: ofensivas, defensivas y de posesión, se han generado las métricas más significativas para cada situación de juego. En concreto, se han definido las siguientes 14 métricas:

- **'shot_effectivity'**: Esta métrica ofensiva representa la efectividad ofensiva del equipo en la finalización de jugadas, y se calcula como la proporción entre el número de goles marcados y el total de tiros realizados. Permite evaluar cuán eficientes son los equipos a la hora de convertir sus oportunidades de disparo en goles, aportando una medida clave de rendimiento en ataque. Un valor elevado en esta métrica indica una alta capacidad de definición, mientras que valores bajos pueden señalar imprecisión o baja calidad en las finalizaciones.

- **‘expected_goals’:** Esta métrica ofensiva cuantifica la cantidad de goles que un equipo debería haber marcado en función de la calidad y las características de sus oportunidades de disparo. Se calcula asignando un valor probabilístico a cada intento de gol basado en factores como la posición del tiro, el tipo de disparo, la presión defensiva y otras variables contextuales. El porcentaje de goles esperados refleja la probabilidad acumulada de éxito ofensivo, ofreciendo una estimación objetiva del rendimiento ofensivo más allá del resultado real. Un valor alto indica que el equipo genera oportunidades de alta calidad, mientras que discrepancias significativas entre goles reales y esperados pueden señalar suerte, errores del portero o ineficiencia en la definición.
- **‘shot_passes_percentage’:** Esta métrica ofensiva representa el porcentaje de pases realizados por un equipo que terminan en un disparo a puerta. Refleja la capacidad del equipo para crear oportunidades ofensivas a partir de su juego de pase, midiendo la efectividad y el propósito directo de sus acciones en la generación de tiros. Un valor alto indica que el equipo es eficiente en construir jugadas que conducen a intentos de gol, mientras que valores bajos pueden sugerir un juego menos directo o dificultad para encontrar posiciones de disparo.
- **‘dangerous_setpiece_throwin’:** Esta métrica defensiva cuantifica las acciones peligrosas que un equipo recibe a balón parado y en centros, específicamente en situaciones como saques de esquina, tiros libres y saques de banda (throw-ins) que generan oportunidades de disparo o asistencias para gol. Se calcula identificando los pases de balón parado que resultan en asistencias de tiro o gol para el equipo contrario, reflejando así la vulnerabilidad defensiva en estas fases estáticas y en la recepción de centros, es decir, la defensa aérea y del balón parado. Un valor elevado indica que el equipo concede un número significativo de situaciones ofensivas peligrosas a través de jugadas a balón parado o centros, lo que puede señalar debilidades en la defensa posicional y aérea.
- **‘dangerous_passes’:** Esta métrica ofensiva cuantifica el número de pases que un equipo realiza y que terminan dentro del área rival. Representa la capacidad del equipo para generar oportunidades de ataque a partir de pases que acercan el balón a zonas de alta probabilidad de gol. Un mayor número de pases peligrosos indica un juego ofensivo más incisivo y efectivo en la creación de situaciones de peligro, mientras que valores bajos pueden reflejar dificultades para penetrar la defensa adversaria.
- **‘successful_dribbles_percentage’:** Esta métrica ofensiva representa el porcentaje de regates que un jugador o equipo realiza con éxito, es decir, aquellas acciones en las que el poseedor del balón supera a un adversario manteniendo la posesión. Refleja la habilidad técnica y la capacidad para desequilibrar defensas contrarias mediante conducción individual. Un porcentaje superior de regates exitosos puede indicar una apuesta por una mayor libertad en fase ofensiva, así como la facilidad para superar líneas defensivas. En cambio, un porcentaje inferior puede denotar dificultades para superar la defensa rival y una apuesta ofensiva más conservadora.

- **‘high_press_recoveries’**: Esta métrica ofensiva mide el número de recuperaciones de balón que un equipo realiza en el último tercio del campo rival, es decir, mediante presión adelantada sobre el adversario. Refleja la capacidad defensiva proactiva del equipo para recuperar la posesión cerca de la portería contraria, generando oportunidades de ataque rápidas y reduciendo el tiempo de reacción del rival. Un alto valor en esta métrica indica efectividad en la presión alta y un estilo de juego agresivo orientado a la recuperación temprana del balón, en oposición a un estilo más cauteloso.
- **‘progressive_pases’**: Esta métrica de posesión cuantifica los pases que avanzan el balón más de 10 metros en dirección a la portería rival. Representa la capacidad del equipo para progresar rápidamente en el campo mediante pases largos o precisos que superan líneas defensivas. Cuando se relaciona con la velocidad de juego, un alto número de pases progresivos indica un estilo ofensivo dinámico y vertical, que busca acelerar la transición y generar oportunidades antes de que la defensa adversaria se reorganice. Por el contrario, un bajo valor puede reflejar un juego más pausado y basado en la posesión del balón.
- **‘carry_total_duration’**: Esta métrica de posesión representa la duración total acumulada de las conducciones del balón realizadas por el equipo a lo largo del partido. Mide el tiempo efectivo durante el cual los jugadores mantienen el control del balón mientras avanzan con él, reflejando la capacidad del equipo para progresar mediante el regate o el desplazamiento controlado en el campo. Un valor elevado en esta métrica puede indicar un estilo de juego basado en la posesión y la construcción pausada, mientras que valores bajos podrían señalar un enfoque más directo o menos protagonismo en la conducción individual.
- **‘effective_possession’**: Esta métrica de posesión representa el porcentaje de pases completados por un equipo dentro del campo rival. Refleja la capacidad del equipo para mantener y controlar el balón en zonas ofensivas, lo cual es fundamental para generar oportunidades de ataque y ejercer presión sobre la defensa contraria. Un alto porcentaje de posesión efectiva indica precisión y dominio en el último tercio del campo, mientras que valores bajos pueden señalar dificultades para progresar o mantener la posesión en áreas peligrosas.
- **‘own_half_disposses’**: Esta métrica de posesión y defensiva refleja la cantidad de veces que un equipo pierde la posesión del balón en su propio campo. Mide las pérdidas de balón dentro de la mitad defensiva del terreno de juego, lo cual es crucial para evaluar la seguridad y el control que un equipo tiene sobre el balón en zonas donde conceder la posesión puede resultar especialmente peligroso. Un valor alto en esta métrica indica que el equipo es más propenso a errores o presión adversaria efectiva en su campo, aumentando el riesgo de contraataques y situaciones defensivas comprometidas.
- **‘defensive_actions’**: Esta métrica defensiva agrupa las acciones defensivas exitosas realizadas por un equipo en su propio campo, incluyendo tanto duelos defensivos ganados como intercepciones efectivas. Los duelos defensivos se refieren a enfrentamientos

individuales en los que el jugador recupera o mantiene el balón, mientras que las intercepciones capturan la capacidad del equipo para anticipar y cortar pases rivales. Al centrarse en acciones dentro del campo propio, esta métrica evalúa la solidez defensiva y la capacidad para neutralizar ataques contrarios antes de que lleguen a zonas peligrosas. Un valor elevado indica una defensa activa y eficaz en la contención y recuperación de balón en áreas críticas.

- **‘ppda’**: También conocida como “Pases Permitidos por Acción Defensiva”, mide la cantidad de pases que un equipo permite a su oponente por cada acción defensiva realizada (duelos ganados o intercepciones) durante el partido. Se calcula dividiendo el número de pases completados por el adversario entre las acciones defensivas efectivas del equipo. Un valor bajo de PPDA indica una presión defensiva intensa y eficaz, limitando la capacidad del rival para mover el balón con facilidad, mientras que un valor alto sugiere una menor agresividad defensiva y mayor libertad para el adversario en la circulación del balón. Por tanto, PPDA es una medida clave para evaluar la efectividad y el estilo defensivo de un equipo, especialmente en cuanto a su capacidad para presionar y recuperar la posesión rápidamente.
- **‘opponent_shots’**: Esta métrica defensiva cuantifica el número de tiros que el equipo concede a sus rivales desde la zona crítica del campo, definida horizontalmente desde el área hasta la portería (zona 5). Refleja la capacidad defensiva del equipo para limitar las oportunidades de disparo de alta probabilidad por parte del adversario. Un alto valor indica que el equipo está permitiendo un número considerable de intentos de gol desde posiciones peligrosas, lo que puede revelar debilidades en la presión defensiva o en la organización táctica cerca del área propia.

Desde un punto de vista técnico, el tratamiento de los datos se ha llevado a cabo principalmente mediante la creación, transformación y edición de estructuras tipo “dataframe”. Estas estructuras, propias del entorno de trabajo en Python con la librería “pandas”, permiten manipular conjuntos de datos de forma eficiente, aplicando filtros, transformaciones y operaciones sobre columnas específicas. La base del análisis ha sido el dataframe de eventos (*‘events’*), que contiene información detallada sobre todas las acciones registradas durante los partidos, como pases, tiros, recuperaciones, faltas, entre otros. A partir de este conjunto de datos se ha procedido a generar nuevos dataframes auxiliares, cada uno correspondiente a una métrica concreta.

Para ello, se han aplicado filtros condicionales para seleccionar únicamente aquellos eventos relevantes para la métrica deseada (por ejemplo, filtrar solo los tiros a puerta o los pases completados), y posteriormente se han realizado agrupaciones por partido y por equipo, con el fin de consolidar los datos a un nivel de análisis colectivo. Una vez agrupados, se han aplicado operaciones matemáticas básicas, como sumas, diferencias, promedios o proporciones, que han permitido construir indicadores interpretables y útiles para el modelado posterior. Esta metodología permite no solo estructurar los datos de forma clara, sino también crear métricas adaptadas al contexto del análisis, evitando el uso de variables genéricas o poco representativas. El enfoque basado en la manipulación de dataframes resulta especialmente flexible, ya que permite generar nuevas métricas a partir de los eventos sin necesidad de reestructurar

todo el conjunto de datos original, facilitando la escalabilidad y replicabilidad del análisis.

Además, en el proceso de generación de estas nuevas variables, se ha llevado a cabo un tratamiento adecuado de los datos faltantes. En los casos en los que una métrica pudiera no estar definida por falta de datos (por ejemplo, divisiones por cero o registros incompletos), se ha aplicado un método de imputación por defecto, asignando el valor cero o el valor medio, según el caso, para mantener la coherencia del conjunto de datos sin introducir distorsiones. Una vez generadas, todas las métricas han sido revisadas y validadas para asegurar que su escala, su distribución, su tamaño y su significado fueran adecuados para su uso posterior en los modelos de aprendizaje automático.

Por último, se procede con la consolidación en un único conjunto de datos estructurado por equipo y partido. Para ello, se ha llevado a cabo un proceso de agrupación y fusión secuencial de dataframes, en el que cada métrica calculada previamente en su propio dataframe se ha integrado con el resto a través una clave común compuesta por los campos *'match_id'* (identificador del partido) y *'team'* (equipo). Se ha construido progresivamente un dataframe denominado *'match_metrics'*, que contiene todas las métricas seleccionadas para cada equipo en cada encuentro. Este procedimiento asegura una estructura homogénea y facilita el análisis conjunto de todas las variables explicativas generadas. La agrupación paso a paso garantiza además que no se pierda información relevante y que todas las métricas estén correctamente alineadas respecto a la unidad de análisis definida. Una vez creado este dataframe consolidado, se ha procedido a integrar la variable objetivo, correspondiente a la diferencia de goles obtenida por cada equipo en cada partido. Para ello, se ha realizado una fusión con el dataframe *'matches'*, que contiene la información sobre los resultados de los partidos, y se ha creado una nueva columna *'goal_diff'*. Esta columna toma el valor de la diferencia de goles en función de si el equipo en cuestión actuó como local o visitante, eliminando las columnas de local y visitante tanto en el ámbito de diferencia de goles como de nombre de equipo.

Este dataframe final, denominado *'metrics'*, formado por las columnas: *'match_id'* (identificador del partido), *'team'* (equipo), *'goal_diff'* (diferencia de goles del equipo en cuestión para el partido con dicho identificador) y una columna por cada métrica de juego. En concreto, disponemos de un dataframe compuesto por 500 filas y 17 columnas, que representa la estructura definitiva del conjunto de entrenamiento, compuesto exclusivamente por variables relevantes y correctamente alineadas con el objetivo del proyecto.

5.4 Aprendizaje automático

En esta sección se aborda el proceso de modelado del rendimiento colectivo en el fútbol profesional mediante técnicas de aprendizaje automático, centrando el análisis en el uso de modelos de regresión. La elección de esta familia de modelos se justifica por la naturaleza de la variable objetivo definida en el proyecto: la diferencia de goles obtenida por un equipo en cada partido. Esta variable representa una magnitud numérica continua, lo que la convierte en un caso típico para técnicas de regresión, cuyo propósito es establecer relaciones cuantitativas entre un conjunto de variables explicativas y un resultado continuo.

A diferencia de otros enfoques como la clasificación, que segmentan los datos en categorías discretas (victoria, empate, derrota), la regresión ofrece una representación más granular y rica del rendimiento del equipo, permitiendo capturar variaciones en el margen de victoria o derrota. Esto resulta especialmente útil en el contexto del análisis táctico, donde pequeñas diferencias en el marcador pueden tener un gran impacto estratégico.

El enfoque basado en regresión no solo proporciona capacidad predictiva, sino que también ofrece un marco interpretativo robusto para entender el papel de cada métrica en el rendimiento global. Los coeficientes de los modelos regresivos permiten cuantificar el impacto relativo de cada variable, facilitando la identificación de los factores más determinantes en el comportamiento colectivo del equipo. Esta dimensión interpretativa resulta fundamental para uno de los objetivos clave del proyecto: no solo anticipar el rendimiento, sino también explicar y justificar los resultados obtenidos a partir de métricas específicas.

Dado que el conjunto de datos incluye un número moderado de variables con posibles correlaciones entre sí, y que existe el riesgo tanto de sobreajuste como de redundancia en las variables, se ha optado por aplicar y comparar diferentes tipos de regresión regularizada y no regularizada. Este enfoque comparativo tiene como finalidad seleccionar el modelo que ofrezca el mejor equilibrio entre precisión, capacidad de generalización e interpretabilidad.

Para ello se han realizado dos implementaciones distintas, en primer lugar, una excluyendo la variable *'team'* para evitar el sobreajuste basado en el nombre del equipo y centrando el foco del análisis únicamente en las métricas puramente deportivas. Y, en segundo lugar, categorizando la variable *'team'* mediante la técnica de codificación "one-hot", que se explicará posteriormente. A continuación, se detallan los distintos métodos de regresión implementados y su justificación dentro del análisis.

A continuación, se explican los diferentes modelos de aprendizaje automático implementados, para los que se ha adoptado la partición 80 - 20 ya que se trata de una estrategia de entrenamiento ampliamente aceptada, que permite entrenar modelos robustos y, al mismo tiempo, evaluar su capacidad de generalización de forma efectiva.

5.4.1 Regresión lineal

Como punto de partida en el análisis de regresión, se ha implementado un modelo de Regresión Lineal Múltiple, cuyo objetivo es estimar la relación lineal entre un conjunto de variables explicativas (las métricas de rendimiento definidas previamente) y la variable objetivo, correspondiente a la diferencia de goles obtenida por un equipo en cada partido.

La Regresión Lineal es uno de los modelos más clásicos y utilizados dentro del aprendizaje automático supervisado para problemas de predicción de variables continuas. Su simplicidad y carácter interpretativo la convierten en una herramienta útil para establecer una primera aproximación a la influencia que cada métrica tiene sobre el resultado final del partido. El modelo ajusta una función lineal de la forma:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

Figura 5.3: Fórmula para la Regresión Lineal.

El conjunto de datos ha sido dividido en subconjuntos de entrenamiento (80%) y prueba (20%), utilizando una partición aleatoria estratificada para garantizar la representatividad de los datos. Posteriormente, se ha entrenado el modelo sobre el conjunto de entrenamiento y se ha generado la predicción sobre los datos de prueba.

Este modelo sirve como línea base para posteriores comparaciones con técnicas más sofisticadas de regresión regularizada, y permite además observar directamente cómo las métricas seleccionadas, en ausencia de información contextual del equipo, se comportan como predictores del rendimiento en términos de diferencia de goles.

5.4.2 Regresión Lasso

El segundo modelo implementado en este trabajo ha sido la regresión Lasso (Least Absolute Shrinkage and Selection Operator), una variante de la regresión lineal que incorpora un término de regularización L1. Al igual que la regresión lineal múltiple, Lasso tiene como objetivo principal predecir una variable continua a partir de un conjunto de variables independientes. Sin embargo, introduce un mecanismo adicional que permite reducir el sobreajuste y mejorar la interpretabilidad del modelo, especialmente en contextos donde el número de predictores es elevado o existe multicolinealidad. El modelo Lasso busca estimar los coeficientes que minimizan la siguiente función de coste:

$$\mathcal{L}(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Figura 5.4: Fórmula para la Regresión Lasso.

El modelo de regresión Lasso busca encontrar los coeficientes de la ecuación de predicción que minimicen dos cosas al mismo tiempo: la diferencia entre los valores reales y los valores predichos por el modelo y la suma de los valores absolutos de los coeficientes que acompañan a cada variable. Este segundo término actúa como penalización: cuanto más grandes sean los coeficientes del modelo, mayor será la penalización. Esto obliga al modelo a reducir muchos de esos coeficientes, e incluso a hacer que algunos de ellos se conviertan en cero. El resultado es un modelo más simple, que automáticamente descarta las variables que no aportan información relevante.

Para evaluar el rendimiento del modelo, el conjunto de datos se dividió en dos subconjuntos: 80 % para entrenamiento y 20 % para prueba, siguiendo una práctica común en problemas de aprendizaje supervisado.

La regresión Lasso se aplicó utilizando el valor por defecto del hiperparámetro de regularización, α igual a 1. Este valor proporciona un equilibrio razonable entre ajuste y simplicidad del modelo.

5.4.3 Regresión Ridge

El cuarto modelo considerado ha sido la Regresión Ridge, una técnica de regresión lineal regularizada que introduce un término de penalización L2 sobre los coeficientes del modelo. Su objetivo es el mismo que en la regresión lineal múltiple y en la regresión Lasso: predecir una variable continua a partir de un conjunto de predictores. Sin embargo, Ridge penaliza los coeficientes de forma distinta, aplicando una penalización basada en la suma de los cuadrados de dichos coeficientes, en lugar de sus valores absolutos como en Lasso.

Esta penalización tiene un efecto directo sobre el proceso de ajuste: para mayor valor de los coeficientes, mayor será la penalización. Como resultado, el modelo se ve incentivado a mantener los coeficientes en valores moderados, lo que reduce la varianza del modelo y mejora su capacidad de generalización. A diferencia de Lasso, Ridge no elimina completamente ninguna variable, sino que mantiene todos los predictores, repartiendo su influencia de forma más equilibrada. Esto es especialmente útil en situaciones donde existe colinealidad entre variables independientes, ya que Ridge puede manejar dicha redundancia de manera más eficiente que otros métodos. La función de coste que minimiza el modelo es la siguiente:

$$\mathcal{L}(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Figura 5.5: Fórmula para la Regresión Ridge.

Esta penalización tiene como objetivo evitar que el modelo dependa excesivamente de ciertas variables, lo que podría llevar al sobreajuste. Ridge tiende a mantener todos los predictores en el modelo, pero reduce su impacto individual distribuyendo mejor la influencia entre ellos. El equilibrio entre ambos componentes está determinado por un hiperparámetro llamado α , que regula el grado de penalización. En esta implementación, se ha utilizado el valor 1, al igual que en modelo Lasso, lo que implica una penalización moderada.

Para un análisis más exhaustivo, este valor podría optimizarse mediante técnicas de validación cruzada. Al igual que en los modelos previos, el conjunto de datos se dividió en 80 % para entrenamiento y 20 % para prueba, manteniendo la consistencia y asegurando la comparabilidad de los resultados.

5.4.4 Elastic Net

El siguiente modelo implementado ha sido Elastic Net, una técnica de regresión regularizada que combina las penalizaciones L1 (Lasso) y L2 (Ridge) en una única función de coste. Este enfoque híbrido permite aprovechar simultáneamente las ventajas de ambas técnicas, proporcionando un equilibrio entre la selección automática de variables (propia de Lasso) y la estabilidad frente a la colinealidad (característica de Ridge).

Elastic Net resulta especialmente útil en contextos donde el número de variables predictoras es elevado o donde existen correlaciones entre los predictores. A diferencia de Lasso, que puede seleccionar arbitrariamente una entre varias variables correlacionadas, Elastic Net tiende a seleccionarlas en grupo, preservando información estructural relevante del conjunto de datos.

La función de coste que minimiza el modelo combina dos componentes: un término que penaliza la suma de los valores absolutos de los coeficientes (L1), y otro que penaliza la suma de los cuadrados de los coeficientes (L2). Ambas penalizaciones están ponderadas mediante hiperparámetros que determinan el grado de regularización y el peso relativo de cada tipo de penalización. Para este experimento, se ha utilizado la clase ElasticNetCV, que incorpora un procedimiento de validación cruzada para optimizar automáticamente los hiperparámetros alpha y ratio, este último representando el equilibrio entre L1 y L2 (siendo 1 equivalente a Lasso, y 0 equivalente a Ridge). Como en los modelos anteriores, el conjunto de datos se dividió en 80 % para entrenamiento y 20 % para prueba.

Elastic Net proporciona un marco flexible para la regresión regularizada, siendo especialmente valioso cuando se desea equilibrar interpretabilidad, robustez frente al ruido y capacidad predictiva. Su rendimiento se comparará con los modelos anteriores para valorar su eficacia en el contexto específico del análisis de rendimiento deportivo.

5.4.5 Regresión Lasso, Ridge y Elastic Net con validación cruzada

Con el fin de evaluar de manera más robusta y fiable el rendimiento de los modelos de regresión regularizada, se implementó un esquema de validación cruzada con cinco particiones (5-fold) para los tres enfoques principales: Regresión Lasso, Regresión Ridge y Elastic Net.

La validación cruzada es una técnica ampliamente utilizada en aprendizaje automático que consiste en dividir el conjunto de datos en varias particiones o “folds”. En cada iteración, una partición se utiliza como conjunto de prueba mientras que los restantes conforman el conjunto de entrenamiento. Este proceso se repite hasta que cada partición haya sido utilizada como prueba una vez, y los resultados se promedian para obtener una estimación más estable y generalizable del rendimiento del modelo.

El uso de validación cruzada permite mitigar el sesgo que puede introducir la selección aleatoria de un único subconjunto de entrenamiento y prueba, proporcionando una evaluación más exhaustiva sobre la capacidad predictiva y la robustez del modelo frente a distintas muestras del conjunto de datos.

Esta metodología garantiza que la selección del mejor modelo y sus hiperparámetros esté basada en un análisis riguroso y reproducible, fortaleciendo la confianza en las conclusiones derivadas del estudio.

5.4.6 Regresión Random Forest

Como alternativa a los modelos lineales regularizados, se ha implementado un modelo de Regresión Random Forest, un potente algoritmo de aprendizaje automático basado en la combinación de múltiples árboles de decisión para mejorar la precisión y robustez de las predicciones.

Random Forest pertenece a la familia de métodos de ensamblaje y funciona generando un conjunto (“bosque”) de árboles de decisión independientes. Cada árbol se construye a partir de una muestra aleatoria del conjunto de datos original, obtenida mediante muestreo con reemplazo. Además, en cada nodo del árbol, la división óptima se busca considerando únicamente un subconjunto

aleatorio de las variables predictoras, lo que introduce diversidad entre los árboles y reduce la correlación entre ellos.

La predicción final del modelo se obtiene promediando las predicciones individuales de todos los árboles, reduciendo así la varianza y el riesgo de sobreajuste asociados a los árboles individuales. Esto permite a Random Forest capturar relaciones no lineales y complejas entre las variables predictoras y la variable objetivo sin necesidad de asumir una forma funcional específica.

La predicción para un dato nuevo, representado por un vector de características, se calcula como el promedio de las predicciones de cada uno de los árboles que componen el bosque. Formalmente, si se tienen T árboles, la predicción para un dato se expresa como la media aritmética de las predicciones individuales de cada árbol:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

Figura 5.6: Fórmula para la Regresión Random Forest.

Este mecanismo permite que el modelo combine múltiples perspectivas de predicción, mejorando la generalización frente a nuevos datos.

Para asegurar la consistencia entre todos los modelos, el conjunto de datos se dividió en un 80 % para entrenamiento y un 20 % para prueba, utilizando una semilla aleatoria fija para asegurar la reproducibilidad.

5.4.7 Random Forest mediante Grid Search y Randomized Search

Para optimizar el rendimiento del modelo de Random Forest, se aplicaron dos técnicas comunes de búsqueda de hiperparámetros: Randomized Search y Grid Search, ambas utilizando validación cruzada con 5 particiones (5-fold) para garantizar la generalización del modelo.

La búsqueda aleatoria (Randomized Search) explora un espacio amplio de combinaciones posibles de hiperparámetros seleccionando al azar un número fijo de configuraciones. En este caso, se definió un conjunto extenso de posibles valores para parámetros clave como el número de árboles, la profundidad máxima de los árboles, el número mínimo de muestras para dividir un nodo, el mínimo de muestras por hoja y el método para seleccionar las características en cada división.

Se realizaron 20 iteraciones aleatorias y para cada combinación se evaluó el desempeño con validación cruzada. Esta técnica es eficiente cuando el espacio de hiperparámetros es grande, permitiendo explorar más opciones en menos tiempo comparado con un barrido exhaustivo. Los mejores hiperparámetros encontrados por Randomized Search se utilizaron para generar predicciones en el conjunto de prueba, obteniendo métricas de desempeño que reflejan la mejora en la capacidad predictiva del modelo.

El Grid Search, en contraste, evalúa de forma exhaustiva todas las combinaciones posibles dentro de un grid más reducido de hiperparámetros definidos manualmente. En este caso, se probaron distintas configuraciones

para el número de árboles, la profundidad máxima y el número mínimo de muestras necesarias para dividir un nodo.

Aunque es computacionalmente más costoso, el Grid Search permite asegurar que no se omitan combinaciones potencialmente óptimas dentro del espacio definido. El mejor modelo identificado a través del Grid Search fue evaluado sobre el conjunto de prueba, proporcionando una referencia comparativa de rendimiento frente al modelo obtenido por búsqueda aleatoria.

Ambas estrategias permiten encontrar configuraciones más adecuadas del modelo, mejorando la capacidad de predicción y evitando tanto el sobreajuste como el subajuste. La comparación de sus resultados contribuye a seleccionar el modelo más robusto y eficiente para predecir la diferencia de goles a partir de las métricas de rendimiento.

5.4.8 Regresión XGBoost

En este estudio, también se ha implementado el modelo de XGBoost (Extreme Gradient Boosting), una técnica avanzada de aprendizaje automático basada en el ensamblaje secuencial de árboles de decisión. XGBoost se fundamenta en el método de “boosting”, que construye los árboles de forma iterativa, donde cada nuevo árbol intenta corregir los errores residuales cometidos por los árboles anteriores.

A diferencia de Random Forest, que crea múltiples árboles de manera independiente y promedia sus resultados para obtener la predicción final, XGBoost añade cada árbol para mejorar progresivamente el modelo. Esta forma de entrenamiento secuencial permite que XGBoost capture relaciones complejas y no lineales entre las variables predictoras y la variable objetivo con gran precisión.

El modelo funciona optimizando una función de pérdida, que combina dos componentes principales: el error entre los valores reales y las predicciones actuales del modelo. Y una penalización que controla la complejidad del modelo para evitar el sobreajuste.

Durante cada iteración, XGBoost ajusta un nuevo árbol para minimizar esta función de pérdida, sumando gradualmente mejoras sobre las predicciones previas. Esta técnica de optimización basada en gradientes, de ahí el nombre “gradient boosting”, permite construir un modelo robusto y eficiente.

En términos generales, la predicción final para una observación es la suma de las predicciones generadas por todos los árboles construidos hasta ese momento. Para un dato dado, la predicción es la suma de las contribuciones de cada árbol individual, donde cada árbol modela el residuo o el error del conjunto previo de árboles.

En esta implementación, al igual que en el modelo Random Forest, se dividió en 80 % para entrenamiento y 20 % para prueba con una semilla fija para asegurar la reproducibilidad.

5.4.9 XGBoost mediante GridSearch y RandomizedSearch

Siguiendo la misma metodología aplicada para Random Forest, se optimizó el modelo XGBoost mediante dos técnicas de búsqueda de hiperparámetros combinadas con validación cruzada de 5 particiones (5-fold). Primero, se realizó un Grid Search que evaluó de forma exhaustiva diferentes combinaciones de parámetros clave, tales como el número de árboles, la profundidad máxima de los mismos, la tasa de aprendizaje y parámetros relacionados con el muestreo de datos y características. Este enfoque permitió encontrar una configuración óptima dentro de un espacio acotado, ajustando el modelo para maximizar su capacidad predictiva y evitar el sobreajuste.

Posteriormente, se aplicó Randomized Search, que selecciona aleatoriamente un número definido de combinaciones de hiperparámetros dentro de un espacio más amplio. Esta técnica es especialmente útil para explorar un rango más extenso de valores, identificando posibles configuraciones prometedoras en menor tiempo, sin necesidad de evaluar exhaustivamente todas las combinaciones.

Ambas técnicas utilizaron validación cruzada para asegurar la generalización del modelo y evitar el sesgo de los datos de entrenamiento. La selección de los mejores hiperparámetros mediante estas estrategias contribuyó a mejorar el desempeño del modelo XGBoost en la predicción de la diferencia de goles, logrando un equilibrio entre ajuste y capacidad de generalización.

5.4.10 One-Hot Encoding

Tras haber implementado los diversos modelos predictivos sin incluir la variable categórica *team*, se consideró relevante evaluar su impacto incorporándola al conjunto de predictores. Para ello, fue necesario transformar esta variable cualitativa en un formato numérico compatible con los algoritmos de aprendizaje automático.

La técnica utilizada es One-Hot Encoding, un método estándar para convertir variables categóricas en un conjunto de variables binarias (0 o 1). En concreto, cada categoría única dentro de la variable *team* se convirtió en una nueva columna que toma el valor 1 si el equipo está presente en esa observación, y 0 en caso contrario. Con esta transformación, el modelo puede interpretar correctamente la pertenencia a un equipo sin asumir un orden o relación numérica entre los distintos equipos.

La codificación se implementó con la función `get_dummies` de pandas, especificando la eliminación de la primera categoría de cada variable codificada para evitar la multicolinealidad, es decir, eliminar una de las columnas redundantes y así prevenir problemas de dependencia lineal entre las variables codificadas. El conjunto resultante, mantiene todas las métricas anteriores más las variables binarias generadas por la codificación del equipo.

Posteriormente, se reentrenaron todos los modelos previamente probados: Regresión Lineal, Lasso, Ridge, Elastic Net, Random Forest y XGBoost. Además de sus respectivas variantes que utilizan validación cruzada, Grid Search y Randomized Search. Utilizando esta nueva versión del conjunto de datos, permitiendo así evaluar de forma consistente el impacto que tiene la identificación del equipo sobre la capacidad predictiva de cada modelo.

6 Resultados

En la presente sección se exponen los resultados derivados del análisis predictivo de los datos mediante los distintos modelos de regresión aplicados sobre el conjunto de datos. El objetivo ha sido identificar que técnicas de aprendizaje automático aportan una mayor capacidad y precisión a la hora de explicar la variable objetivo en función de las múltiples métricas de juego.

En primer lugar, se evaluaron los diferentes modelos de aprendizaje automático implementados, permitiendo establecer comparaciones cuantitativas entre enfoques. A continuación, se evaluó el impacto de las diferentes métricas personalizadas de juego para conocer su impacto en la métrica que refleja el rendimiento, cumpliendo con el objetivo de este proyecto.

6.1 Evaluación

Para evaluar el rendimiento predictivo de cada uno de los modelos considerados, se han utilizado dos métricas ampliamente reconocidas en problemas de regresión: el coeficiente de determinación R^2 y el error cuadrático medio (MSE). Ambas proporcionan perspectivas complementarias sobre la calidad de las predicciones y permiten comparar de forma cuantitativa la capacidad explicativa de los diferentes enfoques.

El coeficiente de determinación R^2 mide la proporción de la varianza de la variable dependiente que es explicada por el modelo a partir de las variables independientes. Sus valores oscilan entre 1, el modelo explica perfectamente la variabilidad de los datos, y 0, el modelo no explica nada más allá de la media. También es posible que adquiera valores negativos, significando que el modelo tiene un rendimiento peor que simplemente predecir la media. En otras palabras, cuanto mayor es el valor de R^2 , mejor ajusta el modelo a los datos. No obstante, R^2 no penaliza la complejidad del modelo, por lo que debe interpretarse junto a otras métricas.

Previamente a ver los resultados, es necesario matizar el nombre que han recibido ciertos modelos de aprendizaje automático. En su totalidad se corresponden con su nombre habitual, pero algunos tienen matizaciones. Si se ha entrenado mediante validación cruzada, tiene las siglas 'CV'. Además, si se ha implementado Grid Search o Randomized Search, tiene las siglas 'GS' y 'RS' respectivamente.

A continuación, se presenta los resultados obtenidos tras evaluar el MSE para todos los modelos implementados, tanto con la variable '*team*' como sin ella:




Figura 6.1: Comparación de rendimiento mediante R^2 .

En este caso, el mejor desempeño en R^2 se observa con el modelo de Regresión Lineal sin la inclusión de la variable 'team' ($R^2 = 0.517$), lo que indica que aproximadamente el 51.7% de la variabilidad en los datos es explicada por este modelo. Modelos como Ridge con validación cruzada sin equipos y XGBoost mediante Randomized Search con equipos también muestran un rendimiento relativamente alto con valores cercanos a 0.48.

Por otro lado, los modelos con regularización más fuerte, como Lasso y ElasticNet, obtienen valores de R^2 considerablemente más bajos (alrededor de 0.10 a 0.30), lo que indica que estos modelos tienen menor capacidad explicativa para este conjunto de datos. Esto puede deberse a una sobrepenalización que limita la capacidad predictiva.

Por otra parte, el MSE representa la media del cuadrado de las diferencias entre las predicciones del modelo y los valores reales. Cuantifica el error absoluto en términos de unidades al cuadrado, siendo su interpretación: cuanto menor sea el MSE, más precisas son las predicciones del modelo. Penaliza fuertemente los errores grandes, por lo que es especialmente útil para detectar modelos que pueden sobreajustarse o presentar predicciones poco fiables.

A continuación, se presenta los resultados obtenidos tras evaluar el MSE para todos los modelos implementados, tanto con la variable 'team' como sin ella:




Figura 6.2: Comparación de rendimiento mediante MSE.

En este sentido, el modelo de Regresión Lineal sin inclusión de la variable ‘*team*’ presenta el menor MSE (1.35), lo que confirma que es el modelo que comete menos error en sus predicciones. Los modelos basados en técnicas de regularización, como Lasso y ElasticNet, tienen errores significativamente mayores, lo que refuerza la conclusión de que no ajustan bien a los datos.

Los modelos de tipo ensamble, como RandomForest y XGBoost, muestran un rendimiento intermedio en términos de MSE, con valores ligeramente superiores a los del modelo lineal simple pero todavía competitivos.

Por último, se muestra una tabla resumen con todos los datos de rendimiento de cada modelo, tanto con la variable ‘*team*’ como sin ella:

Resumen de métricas de rendimiento de los modelos

Modelo	team	R2	MSE
LinearRegression	Sin	0.5169914970469247	1.3533415244242215
LinearRegression	Con	0.3793132700251409	1.7391021487165577
Lasso	Sin	0.10532267262870032	2.5067964035616446
Lasso	Con	0.10532267262870032	2.5067964035616446
LassoCV	Sin	0.30823265238945774	1.9382629312699782
LassoCV	Con	0.30823265238945774	1.9382629312699782
Ridge	Sin	0.47980917593173444	1.4575226699568733
Ridge	Con	0.4613476408130017	1.5092500452060507
RidgeCV	Sin	0.4863296721639885	1.4392528915637206
RidgeCV	Con	0.4613476408130017	1.5092500452060507
ElasticNet	Sin	0.12682669030103377	2.4465442964455333
ElasticNet	Con	0.12682669030103377	2.4465442964455333
ElasticNetCV	Sin	0.21707542579990413	2.1936763644512483
ElasticNetCV	Con	0.21707542579990413	2.1936763644512483
RandomForest	Sin	0.4678068453549379	1.4911519999999996
RandomForest	Con	0.469957885720404	1.4851250000000003
RandomForestGS	Sin	0.4616819836539491	1.5083132500000003
RandomForestGS	Con	0.4616702122175841	1.5083462323875512
RandomForestRS	Sin	0.46514718847088177	1.4986040926234363
RandomForestRS	Con	0.4649641025688549	1.4991170810123253
XGBoost	Sin	0.3749362826347351	1.7513657808303833
XGBoost	Con	0.39406025409698486	1.6977823972702026
XGBoostGS	Sin	0.4537317752838135	1.5305888652801514
XGBoostGS	Con	0.44309359788894653	1.5603959560394287
XGBoostRS	Sin	0.46891629695892334	1.488043189048767
XGBoostRS	Con	0.48343461751937866	1.447364330291748

Figura 6.3: Resumen de rendimiento de modelos.

En conclusión, los resultados indican que, para este conjunto de datos y problema específico, el modelo de Regresión Lineal Múltiple sin categorizar por equipos es el que mejor se adapta, tanto por su capacidad explicativa como por la precisión de sus predicciones. Esto sugiere que la relación entre las variables predictoras y la variable objetivo podría ser principalmente lineal, y que aplicar transformaciones o regularizaciones más complejas no aporta beneficios adicionales. Además, la diferencia entre aplicar o no la variable ‘team’ no muestra un impacto claro y consistente.

6.2 Análisis de resultados

Los coeficientes obtenidos gracias a la implementación del modelo de regresión lineal reflejan la importancia y dirección del impacto de cada métrica sobre la variable objetivo, que en este caso es la diferencia de goles. A continuación, se muestra una tabla con los coeficientes de impacto (reflejan cuánto cambia la predicción al variar cada característica), obtenidos mediante el entrenamiento del modelo final:

Influencia de las métricas personalizadas sobre la diferencia de goles

Métrica	Coefficiente
shot_passes_percentage	38.19384831705267
shot_effectivity	7.376261778669915
effective_possesion	2.675826283894964
expected_goals	0.2692748705945638
dangerous_passes	0.006728650132069363
ppda	0.0023332280827915728
carry_total_duration	0.0007460882321443929
progresive_passes	-0.0012773934805588097
high_press_recoveries	-0.00540478566037971
defensive_actions	-0.009007294229442324
dangerous_setpiece_throwin	-0.031536632779835504
own_half_disposses	-0.0321156437134103
successful_dribbles_percentage	-0.033467480012301376
opponent_shots	-0.06648473584833693

Figura 6.4: Resumen de impacto de las métricas de juego.

Podemos dividir el análisis de la influencia de las métricas en los grupos definidos a continuación.

Métricas ofensivas con mayor influencia positiva:

- **shot_passes_percentage** (38.19): Esta métrica representa el porcentaje de pases que terminan en un disparo a puerta, indicando la capacidad del equipo para construir jugadas ofensivas efectivas. Su alto coeficiente sugiere que equipos con un juego de pase orientado a generar tiros tienen una ventaja significativa en la diferencia de goles.
- **shot_effectivity** (7.38): Refleja la eficiencia del equipo en convertir sus disparos en goles. Un valor alto implica mayor capacidad de definición y éxito en finalizaciones, lo que se traduce en una clara ventaja ofensiva que impacta positivamente en la diferencia de goles.
- **effective_possesion** (2.68): Esta métrica mide la posesión efectiva en campo rival, destacando la capacidad para controlar el balón en zonas ofensivas. Su influencia positiva indica que mantener la posesión en campo contrario facilita la creación de oportunidades que aumentan la diferencia de goles.
- **expected_goals** (0.27): Representa la cantidad de goles que un equipo debería haber marcado según la calidad de sus oportunidades. Aunque su coeficiente es menor, contribuye positivamente, reflejando que generar chances de alta calidad impacta en la ventaja en el marcador.
- **dangerous_passes** (0.0067): Indica la capacidad de realizar pases dentro del área rival que pueden crear peligro. Su coeficiente pequeño pero

positivo señala que incrementar este tipo de pases ayuda, aunque en menor medida, a aumentar la diferencia de goles.

Métricas defensivas con influencia negativa:

- **opponent_shots** (-0.066): Mide los disparos concedidos al rival desde zonas críticas. Su coeficiente negativo es el más alto en magnitud dentro de las métricas defensivas, lo que confirma que permitir muchos tiros al adversario reduce la diferencia de goles favorable al equipo.
- **dangerous_setpiece_throwin** (-0.0315): Refleja la vulnerabilidad del equipo en jugadas a balón parado y centros peligrosos recibidos. Un valor negativo indica que sufrir estas situaciones está asociado a una reducción en la diferencia de goles.
- **own_half_disposses** (-0.032): Las pérdidas de balón en campo propio son también perjudiciales, aumentando el riesgo de contraataques y facilitando las oportunidades rivales.
- **successful_dribbles_percentage** (-0.033): Aunque intuitivamente un mayor porcentaje de regates exitosos podría parecer positivo, su coeficiente negativo sugiere que, en este contexto, apostar mucho por el regate individual puede estar asociado a un estilo de juego menos efectivo para aumentar la diferencia de goles, posiblemente debido a pérdidas de balón o falta de juego colectivo.

Métricas con influencia neutra:

- **ppda** (0.0023), **carry_total_duration** (0.0007): Estos coeficientes cercanos a cero indican que la presión defensiva medida por pases permitidos y la duración de conducciones de balón no tienen un impacto relevante en la diferencia de goles en este modelo.
- **defensive_actions** (-0.009), **high_press_recoveries** (-0.005), **progressive_passes** (-0.001): Estas métricas reflejan acciones defensivas y ofensivas de transición. Sus coeficientes, aunque negativos, son prácticamente irrelevantes y sugieren que un aumento en estas variables no se traduce directamente en ventaja en el marcador o puede estar compensado por otros factores.

Los resultados obtenidos en el análisis evidencian que el éxito ofensivo, medido a través de la diferencia de goles, depende en gran medida de la capacidad del equipo para construir oportunidades de tiro efectivas y convertirlas en goles. En este sentido, la métrica de porcentaje de pases que finalizan con disparo destaca como el factor más influyente, lo que pone de manifiesto la importancia del juego asociativo y la precisión en el pase para generar situaciones de peligro. Equipos que logran mantener la posesión orientada hacia la portería rival y que consiguen que sus pases culminen en disparos demuestran un estilo de juego proactivo y directo, clave para desequilibrar defensas bien organizadas. Además, siempre es importante la efectividad en los disparos, al final el fútbol es un deporte en el que el valor del gol es muy alto, resalta que no basta con generar oportunidades, sino que la calidad en la finalización es decisiva. Esto refleja la

necesidad de contar con jugadores con buen remate, buena toma de decisiones en zonas de definición y un alto nivel técnico para aprovechar las ocasiones creadas.

Asimismo, la posesión efectiva en campo rival sugiere que mantener el control del balón en zonas ofensivas no solo permite acumular tiros, sino también gestionar el ritmo del partido, desgastar al rival y crear desequilibrios en la estructura defensiva contraria. Equipos con un alto porcentaje de posesión en campo rival suelen imponer su estilo y generar mayores probabilidades de gol.

Por otro lado, el impacto negativo de métricas defensivas como tiros, balón parado y centros, todos concedidos al equipo rival, pone en evidencia la importancia de una defensa sólida y bien organizada, especialmente en situaciones de balón parado, que históricamente representan una fuente frecuente de goles en el fútbol moderno. La capacidad para minimizar estos tiros adversarios y controlar los saques de esquina o tiros libres puede ser determinante en partidos ajustados.

Resulta especialmente interesante la interpretación del coeficiente negativo en el porcentaje exitoso de regates, que puede reflejar que un exceso de conducción individual, si no está acompañada de un juego colectivo eficaz, puede provocar pérdidas de balón y dificultar la generación de oportunidades claras. Esto subraya la importancia del equilibrio entre creatividad individual y fluidez en el juego colectivo.

En definitiva, el análisis muestra que la clave para maximizar la diferencia de goles radica en un modelo de juego que combine la generación constante de oportunidades de calidad, la efectividad en la finalización, y una defensa organizada que limite los tiros rivales, especialmente en fases estáticas. Esto se traduce en un enfoque equilibrado entre posesión ofensiva controlada, precisión en el pase y fortaleza defensiva, elementos que configuran el ADN de los equipos exitosos en el fútbol contemporáneo.

Estos hallazgos no solo aportan una comprensión profunda del rendimiento estadístico, sino que también pueden orientar decisiones tácticas, planes de entrenamiento y políticas de fichajes, priorizando jugadores y estilos que potencien las variables con mayor impacto positivo, al tiempo que refuercen las áreas defensivas vulnerables detectadas.

7 Conclusiones y Trabajo Futuro

El desarrollo de este Trabajo de Fin de Grado ha permitido demostrar la utilidad del aprendizaje automático en el análisis del rendimiento en el fútbol profesional, a través de un enfoque metodológico centrado en métricas de juego derivadas de datos de tracking. A lo largo del proyecto, se ha conseguido construir un modelo predictivo capaz de estimar la diferencia de goles con base en variables específicas, lo que permite obtener una visión cuantitativa y objetiva del rendimiento colectivo de los equipos.

Entre las conclusiones más relevantes del proyecto, cabe destacar la viabilidad técnica de aplicar modelos de regresión para predecir una variable compleja como la diferencia de goles, a partir de un conjunto de métricas diseñadas ad hoc, demuestra que es posible automatizar parte del análisis táctico y evaluativo de los equipos.

El enfoque basado en métricas personalizadas ha aportado una mayor capacidad interpretativa, al reflejar aspectos del juego que van más allá de los eventos simples como goles o tiros. La elección de modelos regularizados ha permitido identificar con claridad qué variables son más relevantes, al tiempo que se evitaba el sobreajuste, aportando robustez y simplicidad al modelo final.

Desde una perspectiva práctica, el modelo puede servir como herramienta complementaria para entrenadores, analistas o cuerpos técnicos interesados en cuantificar el impacto de ciertas decisiones tácticas o estrategias de juego sobre el resultado final.

En cuanto al trabajo futuro, existen múltiples vías de mejora y ampliación del presente proyecto:

- Ampliación de la base de datos: Incorporar mayor cantidad de competiciones, tanto a nivel de selecciones como un futuro análisis a nivel de clubes podría enriquecer el análisis al disponerse de una mayor cantidad de datos.
- Análisis contextual: Integrar variables contextuales como localía, clima, fatiga acumulada o rotaciones en la plantilla podría aportar mayor profundidad al modelo y adaptabilidad a diferentes escenarios competitivos.
- A nivel de aprendizaje automático, es posible la exploración de técnicas más complejas como redes neuronales o integrar técnicas como aprendizaje por refuerzo o análisis en tiempo real.
- Visualización e interfaz: Desarrollar una interfaz gráfica interactiva donde entrenadores o usuarios puedan introducir datos y obtener predicciones automáticas del rendimiento, facilitaría la adopción del sistema en entornos profesionales.

En conclusión, este proyecto no solo ha logrado cumplir sus objetivos iniciales, sino que también ha abierto el camino hacia nuevas formas de integrar la ciencia de datos en el análisis deportivo. La combinación de rigor técnico e interpretación táctica lo convierte en una contribución valiosa dentro del campo del análisis del rendimiento en el fútbol profesional.

8 Bibliografía

- [1] Hewlett Packard Enterprise (HPE), "Análisis de datos," [En línea]. Disponible: <https://www.hpe.com/es/es/what-is/data-analytics.html>
- [2] Google Cloud, "¿Qué es el aprendizaje automático (AA)?," [En línea]. Disponible: <https://cloud.google.com/learn/what-is-machine-learning?hl=es-419>
- [3] Oracle, "¿Qué es el machine learning?," [En línea]. Disponible: <https://www.oracle.com/es/artificial-intelligence/machine-learning/what-is-machine-learning/>
- [4] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow, 2023. [En línea]. Disponible: <https://www.oreilly.com/library/view/hands-on-machine-learning/9781098125967/>
- [5] D. Link, "Data Analytics in Professional Soccer," 2018. [En línea]. Disponible: https://www.researchgate.net/publication/323222607_Data_Analytics_in_Professional_Soccer
- [6] UAX, "El impacto del Big Data en el fútbol: innovación y estrategias," [En línea]. Disponible: <https://www.uax.com/blog/deporte/impacto-big-data-en-el-futbol>
- [7] Universidad Europea, "Big Data en el fútbol: ¿Para qué sirve?," [En línea]. Disponible: <https://universidadeuropea.com/blog/big-data-aplicada-al-futbol/>
- [8] M. Rico-González, J. P. Ortega, A. Méndez, F. M. Clemente, and A. Baca, "Machine learning application in soccer: a systematic review," 2023. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9806754/>
- [9] J. Fernández, L. Bornn, "Wide Open Spaces: A statistical technique for measuring space creation in professional soccer," 2018. [En línea]. Disponible: https://www.researchgate.net/publication/324942294_Wide_Open_Spaces_A_statistical_technique_for_measuring_space_creation_in_professional_soccer
- [10] H. Sarmiento, A. J. Figueiredo, C. Lago Peñas, and Z. Milanovic, "The Influence of Tactical and Situational Variables on Offensive Sequences during Elite Football Matches," 2017. [En línea]. Disponible: https://www.researchgate.net/publication/318616002_The_Influence_of_Tact

ical and Situational Variables on Offensive Sequences during Elite Football Matches

[11] E. Bisong, " Building Machine Learning and Deep Learning Models on Google Cloud Platform," 2019. [En línea]. Disponible: https://link.springer.com/chapter/10.1007/978-1-4842-4470-8_7

[12] TIOBE Software, "TIOBE Index for May 2025," [En línea]. Disponible: <https://www.tiobe.com/tiobe-index/>

[13] P. Kouma Assagnon, "Un framework Python pour l'analyse statistique des ensembles de données de Football Analytics," 2024. [En línea]. Disponible: <https://sonar.ch/global/documents/331160>

[14] Genius Sports, Second Spectrum, [En línea]. Disponible: <https://www.geniussports.com/perform/>

[15] StatsBomb, [En línea]. Disponible: <https://statsbomb.com/es/que-hacemos/soccer-data/>

[16] StatsPerform, Opta Data Vision, [En línea]. Disponible: <https://www.statsperform.com/opta-vision/>

[17] StatsBomb, StatsBomb Open Data, GitHub repository, [En línea]. Disponible: <https://github.com/statsbomb>

[18] Big Data Sports, Datos en el fútbol: los desafíos que vienen, [En línea]. Disponible: <https://bigdatasports.media/2020/12/05/datos-en-el-futbol-los-desafios-que-vienen/>

[19] El Español, El fútbol se reinventa: las nuevas reglas y cómo la tecnología y el Covid han influido en los cambios, [En línea]. Disponible: https://www.elespanol.com/deportes/futbol/20220614/futbol-reinventanuevas-tecnologia-covid-influido-cambios/679932286_0.html

9 Anexos

Anexo A. Repositorio del proyecto

El proyecto, que incluye todo el código desarrollado, se encuentra disponible en la plataforma *GitHub*, accediendo a través del siguiente enlace:

<https://github.com/gonzalosalassaiz/TFG.git>